

分类号

学校代码 10487

学号

密级

华中科技大学

硕士学位论文

(学术型 ☐ 专业型 ☒)

基于 KAN 神经网络的流感多区域传
播预测模型研究

学位申请人：诸雯

学科专业：应用统计

指导教师：林聪萍 副研究员

答辩日期：XXXX 年 XX 月 XX 日

**A Dissertation Submitted in Partial Fulfillment of the Requirements
for the Master Degree in Engineering/Science （工学/理学硕士）
/the Professional Master Degree (专业学位)**

**A Multi-Region Influenza Transmission Forecasting
Model Based on Kolmogorov-Arnold Networks (KAN)**

**Candidate : ZHU Wen
Major : Applied Statistics
Supervisor : Asso. Prof. LIN Congping**

**Huazhong University of Science and Technology
Wuhan 430074, P. R. China
May, 2021**

独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权华中科技大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保 密 ☐，在 _____ 年解密后适用本授权书。

本论文属于 不保密 ☐。

（请在以上方框内打“√”）

学位论文作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

摘要

针对多区域流感传播预测中非线性拟合能力与流行病学可解释性难以兼顾、物理机制与数据驱动方法融合不足的问题,本文提出一种融合 Kolmogorov-Arnold 网络 (KAN) 与 Graphormer 的物理信息混合模型。以全国 24 个中心城市为研究对象,整合流感病例、人口流动和环境气象等多源数据,旨在提高多区域流感传播预测精度,并增强模型对传播动力学机制的刻画与解释能力。

首先,本文采用保形分段三次插值方法将省级月度病例降尺度为城市日度序列;基于重力模型重构城市间绝对人口流量矩阵,并引入扩散距离替代地理距离,以刻画人口流动驱动的空间关联。其次,在模型构建中,利用门控时序卷积网络提取时序特征,结合改进中心度编码和基于扩散距离的空间偏置增强 Graphormer 对空间依赖的表征能力,并通过 Kolmogorov-Arnold 网络中的 B 样条可学习激活函数提升非线性映射能力。同时,将反应-扩散-漂移方程嵌入模型训练过程,构建兼顾数据拟合与动力学约束的多任务损失函数。

实验结果表明,在严格时序划分下,本文所提模型的决定系数达到 0.9432,均方根误差为 1.8359;反演得到的时变有效再生数均值为 1.011,其中 93.06%的估计值落入[0.5, 2.0]的流行病学合理区间。从机制层面看,注意力分析揭示了人口流动驱动的跨区域传播路径,参数结果显示南方城市平均传播率显著高于北方城市。本文所构建的模型在提升预测精度的同时,实现了传播动力学参数的可解释性反演,从而为多区域传染病传播的风险评估与精准防控提供方法论支撑。

关键词: 流感传播预测; Kolmogorov-Arnold 网络; Graphormer; 物理信息神经网络; 多区域模型

Abstract

To address the difficulty of reconciling nonlinear fitting capability with epidemiological interpretability, as well as the insufficient integration of physical mechanisms and data-driven methods in multi-region influenza transmission forecasting, this thesis proposes a physics-informed hybrid model integrating the Kolmogorov-Arnold Network (KAN) and Graphormer. Taking 24 central cities in China as the study nodes, multi-source data on influenza cases, population mobility, and environmental meteorological factors are integrated to improve forecasting accuracy and enhance the characterization and interpretation of transmission dynamics.

First, the Piecewise Cubic Hermite Interpolating Polynomial method is employed to downscale provincial monthly case data into city-level daily series. An absolute inter-city population flow matrix is then reconstructed based on a gravity model, and diffusion distance is introduced in place of geographical distance to characterize mobility-driven spatial associations. Subsequently, a Gated Temporal Convolutional Network is utilized to extract temporal features, while Graphormer is enhanced by improved centrality encoding and diffusion-distance-based spatial bias to capture spatial dependencies. The B-spline learnable activation functions in KAN are further adopted to strengthen nonlinear representation. A reaction-diffusion-advection equation is incorporated into the training process as a physical constraint, and a multi-task loss function is constructed to jointly optimize data fitting and transmission dynamics.

Experimental results demonstrate that, under a strict chronological split, the proposed model achieves an R^2 of 0.9432 and an RMSE of 1.8359. The mean inferred time-varying effective reproduction number is 1.011, with 93.06% of the estimates falling within the epidemiologically plausible interval of $[0.5, 2.0]$. Attention analysis further reveals cross-regional transmission pathways driven by population mobility, and parameter estimates indicate that the average transmission rate in southern cities is significantly higher than that in northern cities. These findings demonstrate that the proposed model improves forecasting accuracy while enabling interpretable inversion of transmission-related dynamical parameters, thereby providing methodological support for risk assessment and precise

control of multi-region infectious disease transmission.

Key words: influenza transmission forecasting, Kolmogorov-Arnold Network, Graphormer, physics-informed neural network, multi-region model

目 录

摘 要.....	I
Abstract.....	II
1 绪论.....	1
1.1 研究背景与意义	1
1.2 传染病预测模型研究现状	3
1.3 本文研究目标与内容	7
1.4 本章小结	10
2 相关理论与方法基础	11
2.1 传染病动力学模型及其时空拓展	11
2.2 图神经网络与 Graphormer 的空间建模	14
2.3 Kolmogorov-Arnold 网络	16
2.4 时空数据处理方法	17
2.5 本章小结	18
3 多源数据融合与实验设计	19
3.1 多源数据采集与整理	19
3.2 时空序列的降尺度与拓扑特征重构	22
3.3 实验评估设计	25
3.4 评估指标与实验环境	25
3.5 本章小结	26
4 基于 KAN-Graphormer 的混合预测模型	27
4.1 模型总体框架	27
4.2 时序特征提取与编码	29
4.3 KAN 非线性映射与参数解码	31

华中科技大学硕士学位论文

4.4	多任务损失与训练策略	33
4.5	消融实验设置	34
4.6	本章小结	35
5	实验结果与分析.....	36
5.1	实验设计：时序划分与对照基准	36
5.2	模型训练过程分析	37
5.3	时序划分下的模型性能对比	38
5.4	动力学参数反演与区域异质性分析	42
5.5	可解释性分析：注意力机制与 KAN 激活函数	45
5.6	残差诊断与模型稳健性	48
5.7	本章小结	49
6	总结与展望.....	50
6.1	核心结论与全景回溯	50
6.2	方法学维度的创新凝练	51
6.3	研究局限的反思与未来展望	51
	致 谢.....	53
	参考文献.....	54
	附录 1 攻读硕士学位期间取得的科研成果	59
	附录 2 其它附录	60

1 绪论

1.1 研究背景与意义

1.1.1 流感传播的公共卫生挑战

流行性感（Influenza，简称流感）是由流感病毒引发的急性呼吸道传染病，具有传播速度快、影响范围广、病毒变异频繁等特征，是全球公共卫生领域长期面临的重大挑战。根据世界卫生组织（World Health Organization, WHO）发布的《季节性流感事实说明书》，全球每年发生 300 万至 500 万例重症流感病例，其中约 29 万至 65 万例患者因流感相关并发症死亡^[1]。流感的暴发不仅对人类健康构成直接威胁，还会引发医疗系统紧张、社会经济活动受阻等一系列连锁反应。

我国作为人口大国，地域辽阔、气候多样，流感传播不仅表现出显著的季节性特征（北方冬春季高发、南方冬春季与夏季双高峰），还存在明显的区域异质性。中国流感中心 2024 年第 1 周监测数据显示，南方省份流感病毒阳性率高达 52.5%，而北方省份为 36.1%。从毒株构成看，南方以 A 型流感为主（占阳性总数的 63.2%），其中绝大部分（99.5%）为 A(H3N2)亚型；北方则以 B 型流感为主导（占比 57.7%），且全部为 B 型 Victoria 系^[1]。这种差异直接导致南北方流感的传播速度、流行强度和防控重点存在显著不同，如表 1-1 所示。

表 1-1 2024 年第 1 周全国流感样病例监测实验室检测结果^[1]

指标	南方省份	北方省份	全国合计
检测数	5863	5707	11570
阳性数（阳性率）	3079（52.5%）	2058（36.1%）	5137（44.4%）
A 型流感（占比）	1945（63.2%）	871（42.3%）	2816（54.8%）
- A(H3N2)（占比）	1936（99.5%）	843（96.8%）	2779（98.7%）
- A(H1N1)pdm09（占比）	9（0.5%）	28（3.2%）	37（1.3%）
B 型流感（占比）	1134（36.8%）	1187（57.7%）	2321（45.2%）
- Victoria 系（占比）	1130（99.6%）	1187（100%）	2317（99.8%）
- Yamagata 系（占比）	0（0%）	0（0%）	0（0%）

上述监测数据显示，流感的传播规律受到地域和毒株类型的双重影响。这种复杂性对疫情的精准预测提出了更高要求：单一区域的预测模型已难以满足跨区域传播的防控需求，急需发展能够同时捕捉时空动态和区域异质性的多区域预测模型。

1.1.2 多区域流感传播的复杂性特征

多区域流感传播是一个涉及时空动态演化、多因素耦合作用的复杂过程，其复杂性主要体现在以下三个方面：

人口流动驱动的跨区域传播特性。在全球化和城镇化加速推进的背景下，我国交通网络日益密集。截至 2023 年底，高铁运营里程突破 4.5 万公里，年发送旅客超 23 亿人次；民航旅客运输量达 6.2 亿人次。密集的交通网络使得流感病毒能够在短时间内实现跨省市、跨区域的快速扩散。传染病的跨区域传播强度与城市间的人口流动热度呈显著正相关^{[3][4]}。例如，2023 年春节假期期间，全国跨区域人员流动量达 2.1 亿人次，节后多地出现流感聚集性疫情，呈现出“外部输入—社区扩散—本地暴发”的传播链条^[5]。传统基于单一区域的预测模型已难以适配这种复杂的传播场景。

时空耦合的传播动力学特性。流感传播不仅具有时间上的连续性（如历史病例数对未来传播的影响），还存在空间上的关联性（如相邻城市或人口流动密切城市间的传播联动）。流感扩散速度与城市间的人员流动强度呈显著正相关，而与地理距离的相关性较弱^[6]。这意味着传统的基于地理距离的空间关联刻画方式存在局限性，需迫切需要引入能够反映人口流动网络结构的时空度量方法。

动态变化的传播参数特性。传染病动力学模型中的核心参数（如传播率 β 、恢复率 γ 、接触率 c ）并非固定不变，而是随时间、空间和干预措施动态调整。值得注意的是，在 COVID-19 大流行期间，各国实施的封城、社交距离等非药物干预措施，改变了流感病毒的自然传播过程，使得模型中的接触率、传播率等关键参数不再是静态常数，而是随着政策强度动态衰减的时间函数^[7]。在实际干预环境下，经典的“基本再生数（ R_0 ）”已难以实时反映疫情态势，取而代之的是能够实时刻画当前传播能力的“有效再生数（ R_t ）”。传统模型通常采用固定参数或分段常数参数进行建模，难以适应参数的动态演化特性，导致中长期预测误差累积。

1.1.3 研究的理论价值与实用意义

本研究旨在将 Kolmogorov-Arnold 网络 (KAN) 引入多区域传染病预测领域, 探索在预测精度和模型可解释性之间找到较好的平衡点。KAN 基于 Kolmogorov-Arnold 表示定理, 通过可学习的 B 样条激活函数实现高效的非线性拟合, 且具有较好的可解释性优势^[8]。目前 KAN 的应用主要集中在函数拟合、偏微分方程求解等领域^{[9][10]}, 尚未有研究将其与图神经网络结合用于处理多区域流感传播的时空关联数据。本研究尝试填补这一空白, 为时空序列预测提供新的技术思路。同时, 通过引入扩散距离替代地理距离^[11], 为复杂网络下的传染病传播建模提供新的空间关联度量方法。

精准的流感传播预测能够为多区域协同防控提供决策支持。通过预测未来一段时间某城市的流感病例变化, 可提前启动防控措施, 降低疫情扩散风险。同时, 本研究模型有望捕捉南北方在毒株构成、传播速度上的差异, 为不同区域制定差异化防控策略提供依据。例如, 针对南方 A(H3N2) 亚型传播速度快的特点, 可重点加强交通枢纽的监测预警; 针对北方 B 型流感流行的特征, 可优化疫苗接种的毒株覆盖范围。

1.2 传染病预测模型研究现状

关于大规模传染病的传播建模, 现有研究主要沿着三条技术路径展开: 动力学模型、数据驱动模型, 以及融合两者的混合模型。本节将从方法论视角梳理各类模型的核心思想、优势及局限性, 在此基础上引出 KAN 网络并指出现有研究的主要缺口。

1.2.1 传染病预测模型的三大研究范式

(1) 动力学模型

传染病动力学模型是基于流行病学原理构建的数学模型, 通过刻画易感者 (S)、感染者 (I)、恢复者 (R) 等群体的状态转换过程, 揭示传染病的传播规律。经典 SIR 模型由 Kermack 和 McKendrick 于 1927 年提出^[12], 其核心方程为:

$$\frac{dS}{dt} = -\beta \frac{SI}{N} \quad (1-1)$$

$$\frac{dI}{dt} = \beta \frac{SI}{N} - \gamma I \quad (1-2)$$

$$\frac{dR}{dt} = \gamma I \quad (1-3)$$

其中 N 表示区域内的常住总人口数，且在短期预测中假设人口总数不变（即 $S + I + R = N$ ）； β 为传播率，指单位时间内一个感染者平均有效接触并传染易感者的次数； γ 为恢复率，通常取平均感染周期的倒数。该模型奠定了传染病动力学的理论基础，但假设参数固定且人群均匀混合，难以适应现实中复杂的传播场景。为提升模型的适用性，研究者们对其进行了多方面扩展：考虑到流感等病毒在感染初期往往没有明显症状，不易被察觉，SEIR 模型通过引入潜伏者（E）状态，消除了纯 SIR 模型在拟合日度新增病例时容易出现的“相位偏移误差”^[13]；元种群（Metapopulation）模型将研究区域划分为多个子区域，通过人口迁移项描述子区域间的传播联动^{[14][15]}。Citron 等对比了不同人口流动模式下元胞模型的传播动力学差异，发现集中式流动比分散式流动更易引发大规模疫情^[16]。

然而，动力学模型存在两个显著局限：一是参数估计难度大，传播率、恢复率等参数通常需通过历史数据拟合或专家经验设定，难以实时反映疫情的动态变化^[17]；二是模型假设过于简化，对人群异质性、病毒变异、防控措施调整等因素考虑不足，且对非线性关系的拟合能力有限，需依赖先验假设简化复杂传播过程，导致中长期预测精度受限^{[13][14]}。

（2）数据驱动模型

数据驱动模型以机器学习、深度学习算法为核心，通过挖掘历史数据中的统计规律实现疫情预测，无需依赖复杂的流行病学假设，具有较强的拟合能力。早期研究主要采用传统机器学习算法，如支持向量机（SVM）、随机森林等^[18]。随着深度学习的发展，研究者们开始采用更复杂的网络结构处理流感传播的时空特征。

图神经网络（Graph Neural Network, GNN）及其变体（时空图神经网络 STGNN）成为多区域传染病预测的热门方法^[19]。GNN 通过将每个区域视为节点，区域间的关联视为边，能够有效捕捉空间依赖关系。La 等设计了基于跨位置注意力的时空图神经网络，成功预测了流感的多区域传播趋势^[20]。Kapoor 等提出的 STGNN 模型利用细粒度人口流动数据，实现了 COVID-19 每日新增病例的精准预测^[21]。Graphormer 作为 GNN 的重要变体，通过中心性编码、空间编码和边编码三种方式，将图拓扑信息融入自注意力机制，在处理动态图结构时展现出较好性能^{[22][23]}。

尽管数据驱动模型拟合精度高,但也存在明显缺陷:一是可解释性弱,模型预测结果缺乏明确的流行病学意义,难以输出具有流行病学意义的参数(如传播率、再生数),无法为防控策略提供机制层面的解释^[7];二是对数据质量依赖较强,当数据存在缺失、异常或分布偏移时,模型性能会明显下降^[21];三是忽略了传染病传播的物理机制,可能出现数据拟合良好但不符合传播规律的情况。

(3) 混合建模模型

混合建模模型结合了动力学模型的物理机制和数据驱动模型的拟合能力,在训练过程中,通过将动力学约束融入数据驱动模型,兼顾机理模型与数据两方面的优势,是近年来传染病预测的研究热点。Kharazmi 等将整数阶和分数阶 SIR 模型嵌入物理信息神经网络(PINN),实现了传染病瞬时参数的识别^[24];He 等将 SEIR 模型融入 PINN,成功识别了 COVID-19 疫情期间的干预强度^[7];Gao 等提出的时空图注意力网络,将 SIR 模型嵌入损失项,提升了模型的长期预测精度和可解释性^[25]。

Wang 等提出的 M-Graphormer 模型是混合建模的代表性工作^[23]。该模型将 Graphormer 与元胞 SIR 模型结合,通过 Graphormer 捕捉空间依赖关系,利用元胞 SIR 模型提供物理约束,实现了多区域传染病的高维参数估计和传播预测。该模型解决了传统 GNN 处理动态图结构时丢失空间依赖的问题,在低数据质量下仍能保持较好的预测性能。后续研究将元种群思想与时空图注意力网络结合,提出了 MPSTAN 等改进模型^{[26][27]}。

然而,现有混合模型仍存在三个关键问题:一是物理约束与数据拟合的平衡问题,多数模型采用静态权重平衡两项损失函数,难以适配不同阶段的疫情特征^[28];二是非线性拟合能力不足,模型中用于特征变换的模块多为多层感知机(MLP),采用固定激活函数(如 ReLU),难以捕捉传染病传播的复杂非线性关系,如人口流动强度与病例数的阈值效应^[8];三是区域异质性适配不足,未充分考虑不同区域在毒株构成、人口流动特性上的差异,导致模型的泛化能力受限。

1.2.2 KAN 的研究现状与应用进展

Kolmogorov-Arnold 网络(KAN)是基于 Kolmogorov-Arnold 表示定理提出的新型神经网络,由 Liu 等于 2024 年正式提出^[8]。与传统 MLP 相比,KAN 的核心差异

在于激活函数的位置和可学习性：MLP 的激活函数位于节点（神经元）上，且采用固定形式；而 KAN 的激活函数位于边（权重）上，且为可学习的单变量函数。在实现中，KAN 通常采用 B 样条函数作为可学习激活函数，通过优化控制点系数实现复杂的非线性映射^[29]。

KAN 自提出以来，因其在拟合精度和可解释性上的双重优势受到学界关注。理论研究方面，Liu 等证明了 KAN 具有更快的神经缩放律（scaling law），其测试误差随参数数量的下降速度显著快于 MLP。在拟合高维函数时，KAN 的测试误差仅为 MLP 的十分之一，而参数量仅为 MLP 的五分之一^[8]。方法优化方面，研究者们提出了网格扩展（Grid Extension）技术，通过动态细化 B 样条网格实现拟合精度的逐步提升；提出了稀疏化、剪枝、符号化等技术，能够自动发现模型中的关键路径和符号函数^[8]。

目前，KAN 的应用主要集中于函数拟合、偏微分方程求解、科学计算等领域。Guo 等将 KAN 与物理信息结合，用于求解流体力学中的偏微分方程，实现了高精度数值解^[9]。Koenig 等探索了 KAN 与常微分方程结合的新范式，在传染病动力学建模中展现出优于 MLP 的拟合性能和可解释性^[10]。但 KAN 在传染病预测领域的应用仍处于起步阶段。现有传染病预测模型中的非线性变换模块多为 MLP，难以充分捕捉传播过程中的复杂非线性关系，而 KAN 的可学习激活函数和高效拟合能力为解决这一问题提供了可能^[8]。同时，KAN 的可解释性优势有助于弥补数据驱动模型“黑箱”的缺陷，为疫情传播机制分析提供新视角。因此，将 KAN 与图神经网络结合，构建适用于多区域流感传播预测的混合模型，具有探索价值。

1.2.3 现有研究的主要缺口

现有多区域流感传播预测研究存在四个主要问题。

时空关联建模的精准性有待提升。现有模型对空间关联的刻画多采用地理距离或静态邻接矩阵，忽略了人口流动驱动的动态传播特性^[5]。例如，北京与上海虽地理距离较远，但因人员流动频繁，流感传播关联可能强于相邻的中小城市。此外，时序特征提取多采用简单的时序卷积或循环神经网络，难以同时捕捉流感传播的长期趋势和短期突变^[21]。引入扩散距离等基于人口流动的空间度量方法有望改善这一状况。

非线性拟合与可解释性难以兼顾。纯数据驱动模型通过复杂网络结构实现高精度拟合，但难以解释预测逻辑^[19-21]；动力学模型和传统混合模型虽具有一定可解释性，但非线性拟合能力有限，难以适应流感传播的复杂非线性关系。KAN 的引入为打破这一僵局提供了可能。

物理机制与数据驱动的平衡方式较为单一。现有混合模型采用静态权重平衡两类损失函数，难以适应疫情不同阶段特征的变化^[28]。这种刚性设计导致模型在疫情不同阶段的预测性能波动较大。动态权重调整策略（如课程学习）值得探索。

区域差异的适配能力有待加强。我国南北方在毒株构成、人口流动特性、气候环境等方面存在显著差异^{[2][12]}，但现有模型多采用统一框架，没有考虑各个地区的不同特点，影响不同地区预测的准确性。融入区域标识特征或可提升模型对南北差异的捕捉能力。

1.3 本文研究目标与内容

1.3.1 研究目标

针对上述问题，本研究提出一种融合 Kolmogorov-Arnold 网络与 Graphormer 的混合预测模型（KAN-Graphormer），旨在实现以下目标：

（1）高精度预测：准确预测 24 个中心城市未来一段时间的流感日度病例数，在时序划分条件下达到较高的预测性能。

（2）动态参数估计：同时输出传播率 $\beta(t)$ 、恢复率 $\gamma(t)$ 、接触修正因子 $\text{contact}(t)$ 等流行病学参数，并计算时变有效再生数 $R_t(t)$ ，为干预措施评估提供量化依据。

（3）可解释建模：通过可视化 KAN 激活函数和 Graphormer 注意力权重，揭示模型对关键特征的响应模式和城市间的传播关联结构。

（4）区域差异适配：引入区域标识特征，提升模型对南北方流感传播差异的捕捉能力。

（5）物理一致性保障：融合反应-扩散-漂移方程作为物理约束，确保模型预测结果符合传染病传播的基本规律。

1.3.2 研究内容

为实现上述研究目标，本研究主要开展以下四个方面的工作：

(1) 多源数据采集与预处理

本研究首先构建了涵盖 2020 年 1 月 10 日至 3 月 15 日全国 24 个中心城市的六类多源数据集，具体数据来源包括：①中国公共卫生科学数据中心提供的法定权威流感病例数据^[30]；②采用自行编写的 Python 脚本（含严格节流与防并发控制）从百度迁徙开放平台获取的脱敏宏观城际迁徙指数数据^[31]，该数据仅用于本研究的非营利性学术建模；③各市统计局发布的统计公报数据^[32-38]；④美国国家海洋与大气管理局（NOAA）^[39]及“天气后报”网站^[40]提供的环境气象数据；⑤百度指数平台采集的城内出行指数（以地铁、公交搜索指数替代）^[41]；⑥中国流感中心发布的流感周报阳性率数据^[1]。

针对上述数据的异构性、多尺度和部分缺失问题，本研究开展系统的数据清洗与预处理工作：采用多源数据交叉验证填补关键变量（如利用天气后报数据补充 NOAA 缺失城市的气温）；针对省级月度病例数据，结合城市人口占比和周度流感阳性率趋势，通过保形分段三次插值（PCHIP）方法将其降尺度为城市日度病例^[42]；对城内出行指数的少量缺失值进行线性插值；对人口流动数据，通过重力模型估算城市间实际人口流量^[43]，构建动态加权的迁出视角邻接矩阵；并基于该矩阵计算扩散距离，以替代传统地理距离，更精准地刻画人口流动驱动的区域间传播关联。

(2) KAN-Graphormer 混合模型架构设计

基于 Kolmogorov-Arnold 表示定理和 Graphormer 的图编码机制^[22]，设计混合预测模型架构：采用门控时序卷积网络提取流感传播的时序特征^[44]；利用 Graphormer 的中心性编码、空间编码（基于扩散距离）和边编码（基于人口流动权重）捕捉空间关联；将 Graphormer 中的 MLP 模块替换为 KAN 模块^[8]，通过可学习的 B 样条激活函数实现高效的非线性拟合；融合反应-扩散-漂移方程作为物理约束^[6]，构建多任务损失函数，并基于课程学习思想设计动态权重调整策略^[45]。

(3) 模型训练与优化

设计分阶段训练策略：先固定动力学模型参数，预训练时序特征提取层和

Graphormer 编码器；再放开所有参数，采用贝叶斯优化进行超参数寻优，结合梯度裁剪和动态学习率这些方法保证训练稳定。针对模型的可解释性，通过可视化 KAN 的 B 样条激活函数形态，分析模型对关键特征（如人口流动、区域标识）的响应方式；通过计算特征的重要性排序，识别影响流感传播的关键驱动因素。

（4）模型验证与结果分析

设计两套实验方案：时序划分（前 60% 样本训练、20% 验证、20% 测试）模拟真实预测场景，防止数据泄露；随机划分（70% 训练、15% 验证、15% 测试）作为对照，评估模型在理想条件下的能力上限。通过消融实验量化 KAN 模块、物理约束损失、扩散距离等核心组件的贡献；通过案例分析验证模型对南北方流感传播差异的适配能力。

1.3.3 论文结构

本文共分为 6 章，具体内容如下：

第一章 绪论。阐述研究背景与意义，综述国内外研究现状，指出现有研究存在的问题，明确本文的研究目标、研究内容和论文结构。

第二章 相关理论与方法基础。介绍传染病动力学基础（SIR 模型、SEIR 模型、元种群模型、反应-扩散-漂移方程）、图神经网络核心技术（Graphormer 的编码机制、门控时序卷积网络）、KAN 的理论基础与实现方法（Kolmogorov-Arnold 表示定理、B 样条激活函数）、时空数据处理方法（重力模型、扩散距离计算），为后续模型设计提供理论支撑。

第三章 数据预处理与实验设计。详细描述多源数据的采集来源、数据清洗流程、特征工程构建方法；介绍重力模型估算人口流动量的具体过程、扩散距离的计算方法；设计时序划分与随机划分两套实验方案，明确评估指标和实验环境。

第四章 基于 KAN-Graphormer 的混合预测模型。详细描述模型的整体架构，包括时序特征提取层（Gated TCN）、空间依赖建模层（Graphormer with Diffusion Distance）、KAN 特征变换层、动力学解码器的设计细节；定义多任务损失函数，阐述物理约束与数据拟合的动态平衡机制；列出消融实验的模型及参数设置。

第五章 实验结果与分析。展示时序划分下各模型的预测性能对比、参数合理性

分析结果；通过消融实验量化各组件贡献；通过注意力可视化揭示城市间的传播关联结构；通过 KAN 激活函数可视化分析关键特征的响应模式；对比随机划分实验结果，验证时序划分的必要性。

第六章 总结与展望。总结全文主要研究内容和结论，提炼研究的创新点；分析研究存在的不足；对未来的研究方向进行展望。

1.4 本章小结

本章围绕多区域流感传播预测这一研究主题，系统阐述了研究背景与意义，分析了流感传播的公共卫生挑战和多区域传播的复杂性特征。通过对国内外研究现状的综述，梳理了动力学模型、数据驱动模型、混合模型三大研究范式的进展与不足，介绍了 KAN 的理论基础和应用现状，指出现有研究在时空关联建模、非线性拟合、物理-数据平衡、区域异质性适配等方面的研究缺口。在此基础上，明确了本文的研究目标、研究内容和论文结构。本研究的核心创新点体现在 KAN 与 Graphormer 的融合架构设计、动态权重的多任务损失函数、区域差异适配方法三个方面，旨在构建一种兼具预测精度和可解释性的多区域流感传播预测模型。

2 相关理论与方法基础

传染病的时空演化，本质上是微观病毒感染动力学与宏观人口流动模式在多尺度上的复杂耦合。本章旨在系统性地梳理支撑本研究的理论基石，并非简单的文献罗列，而是试图揭示宏观动力学模型、空间图神经网络与高维非线性映射三者数学机理上的内在联系与互补性，为后续 KAN-Graphormer 混合架构的构建铺设一条逻辑清晰的理论路径。2.1 节从经典的 SIR 模型出发，论证其局限性并引入更符合流感传播特征的 SEIR 动力学系统，进而拓展至多区域元种群模型，为后续的物理约束奠定基础；2.2 节转向空间依赖建模，剖析 Graphormer 如何通过改良的编码机制，将复杂的空间拓扑（如扩散距离）融入 Transformer 的全局注意力中；2.3 节则聚焦于非线性映射的一个新进展——Kolmogorov-Arnold 网络（KAN），探讨其相较于传统多层感知机（MLP）在可解释性与拟合效率上的优势；2.4 节作为理论与数据的桥梁，阐述如何将原始的、非结构化的百度迁徙数据，通过重力模型和扩散距离转化为模型可用的、具有物理意义的输入特征。

2.1 传染病动力学模型及其时空拓展

传染病动力学模型，也称为仓室模型，是用一组微分方程来描述疾病在人群里的传播规律。在本研究中，它一方面给数据生成提供了一些先验的假设，另一方面也用来约束神经网络，避免它算出一些不太符合实际情况的结果。

2.1.1 从 SIR 到 SEIR：潜伏期的引入与有效再生数

上世纪 20 年代，Kermack 与 McKendrick 提出的 SIR（易感者-感染者-恢复者）模型奠定了理论流行病学的基石^[12]。它将人群划分为三个互斥的仓室，并用常微分方程组描述其状态转移。但这一经典框架假设人被感染后马上就能传染给别人。对于流感这种呼吸道传染病来说，这个前提有点理想化，因为病毒其实需要先潜伏一段时间，在身体里复制到一定量之后才具备传染能力。若强行使用 SIR 模型拟合此类数据，将不可避免地产生“相位偏移误差”，即模型预测的疫情波峰会滞后于真实峰值。

为纠正这一系统性偏差，本研究在底层动力学模型中引入了潜伏者（Exposed, E）

仓室，构建了更符合生物学事实的 SEIR 模型。考虑到研究时间窗口（2020 年初）与人口规模的量级，在模型中纳入了自然出生与死亡这一极慢时间尺度的动力学过程，以确保方程组的长期数值稳定性。完整的 SEIR 动力学系统可由以下方程组描述：

$$\frac{dS}{dt} = \mu N - \beta(t) \frac{SI}{N} - \mu S \quad (2-1)$$

$$\frac{dE}{dt} = \beta(t) \frac{SI}{N} - (\sigma + \mu)E \quad (2-2)$$

$$\frac{dI}{dt} = \sigma E - (\gamma(t) + \mu)I \quad (2-3)$$

$$\frac{dR}{dt} = \gamma(t)I - \mu R \quad (2-4)$$

其中，总人口 $N = S + E + I + R$ 在封闭系统中守恒； $\beta(t)$ 与 $\gamma(t)$ 分别为时变的传播率与恢复率，它们的动态变化捕捉了非药物干预（如佩戴口罩、社交隔离）以及公众风险意识改变对传播过程的影响； σ 是潜伏期向感染期转化的速率常数（即平均潜伏期的倒数）； μ 为自然出生与死亡率，用以维持人口基数稳定。在标定易感人群规模时，本研究统一采用各城市的常住人口作为分母 N ，以精确反映真实的暴露风险人群。

在经典流行病学中，基本再生数 $R_0 = \beta/\gamma$ 常被用作衡量疫情爆发潜力的指标^[7]。然而， R_0 描绘的是病原体入侵一个完全易感且无任何干预的人群时的理想化场景。在武汉封城等强力干预措施下，这一前提已不复存在。因此，本研究不再拘泥于静态的 R_0 ，而是通过下一代矩阵方法^[46]，动态计算能够实时反映干预效果的有效再生数 R_t 。在多斑块网络中， R_t 的谱半径更能精确地刻画疫情在空间传播中的瞬时特征，为评估封城等政策的有效性提供关键的指标。

2.1.2 元种群模型：耦合空间异质性与人口流动

前述的 SEIR 模型假设的是人群是均匀混在一起的，这个前提放在单个城市里来看，基本上还能说得过去。然而，当将视角扩展到包含 24 个中心城市的区域网络时，人口流动驱动的跨城传播便成为不可忽略的主导因素。为刻画这一现象，学术界引入了元种群(Metapopulation)网络理论^{[14][15]}。该理论将每个城市视为一个遵循内部 SEIR 动力学的“元胞”，而元胞之间则通过一个离散的人口迁移率矩阵 $M(t) = \{m_{ij}(t)\}$ 进行耦合。矩阵中的元素 $m_{ij}(t)$ 表示 t 时刻从城市 i 到城市 j 的人口流动强度，它

随春节迁徙、封城解封等事件而动态变化。

节点 i 的动力学方程因此修正为：

$$\frac{dS_i}{dt} = \mu N_i - \beta_i(t) \frac{S_i I_i}{N_i} - \mu S_i + \sum_{j \neq i} (m_{ji} S_j - m_{ij} S_i) \quad (2-5)$$

$$\frac{dE_i}{dt} = \beta_i(t) \frac{S_i I_i}{N_i} - (\sigma + \mu) E_i + \sum_{j \neq i} (m_{ji} E_j - m_{ij} E_i) \quad (2-6)$$

$$\frac{dI_i}{dt} = \sigma E_i - (\gamma_i(t) + \mu) I_i + \sum_{j \neq i} (m_{ji} I_j - m_{ij} I_i) \quad (2-7)$$

其中, S_i 、 E_i 、 I_i 分别表示城市 i 内各仓室的人数, N_i 为该城市常住人口; m_{ij} 为从 i 到 j 的人口流动率。右侧最后两项分别表示从其他城市迁入和迁出对该城市各仓室的影响。在工程实现上, 采用四阶龙格-库塔法对其进行离散化迭代求解, 该方法比简单的欧拉法具有更高的精度, 能有效抑制由高频人口流动数据带来的数值震荡, 保证物理约束的稳定性。

2.1.3 反应-扩散-漂移方程：连续空间视角

若将视角从离散的城市节点转移到连续的时空流形, 传染病的蔓延则可被建模为一个反应-扩散-漂移过程^[43]。这为研究提供了一种观察疫情传播的宏观连续视角, 其偏微分方程形式如下：

$$\frac{\partial I(x,t)}{\partial t} = D \nabla^2 I(x,t) + \beta(x,t) \frac{S(x,t)I(x,t)}{N(x,t)} - \gamma I(x,t) + v \cdot \nabla I(x,t) \quad (2-8)$$

方程右侧各项的物理意义如下：

- $D \nabla^2 I(x,t)$: 扩散项, 描述因个体随机移动导致的局部传播, 其中 D 为扩散系数, ∇^2 为拉普拉斯算子;
- $\beta(x,t) \frac{S(x,t)I(x,t)}{N(x,t)}$: 反应项, 表示局部感染过程, $\beta(x,t)$ 为随时空变化的传播率;
- $-\gamma I(x,t)$: 恢复项, 表示感染者因康复或死亡离开传染期;
- $v \cdot \nabla I(x,t)$: 漂移项, 描述由规律性人口流动 (如通勤、迁徙) 引起的定向传播, v 为漂移速度向量。

在训练过程中, 方程(2-8)所描述的物理过程会被转化为一项约束条件, 其计算得到的残差将直接嵌入模型的总损失函数, 以此引导神经网络的预测轨迹尽可能贴近真实世界中连续的传染病传播规律。

2.2 图神经网络与 Graphormer 的空间建模

面对由 24 个城市及其动态连接构成的空间网络，传统卷积神经网络（CNN）因其对欧几里得结构的依赖而难以直接应用。图神经网络（GNN）的出现，为解决此类非欧几里得数据建模提供了全新的思路^[19]。

2.2.1 图神经网络的基本原理

图神经网络的核心思想是“聚合-组合”^[19]。节点通过迭代地聚合其邻居的信息来更新自身的表示。其数学形式可表达为：

$$a_i^{(l)} = \text{AGGREGATE}^{(l)} \left(\{h_j^{(l-1)} : j \in N(i)\} \right) \quad (2-9)$$

$$h_i^{(l)} = \text{COMBINE}^{(l)} \left(h_i^{(l-1)}, a_i^{(l)} \right) \quad (2-10)$$

其中， $N(i)$ 表示节点 i 的邻居集合， $h_i^{(l)}$ 为节点 i 在第 l 层的隐藏表示， $h_i^{(0)}$ 为输入特征， $a_i^{(l)}$ 为聚合邻居信息后得到的中间表示。通过多层堆叠，GNN能够捕捉节点之间更远距离的依赖关系，为空间关联建模提供了基础。这一机制虽然在捕获局部关联上有显著成效，但随着网络层数的加深，节点表征会趋向于一致，即陷入“过平滑”问题。这一特性对于传染病建模而言影响极大——因为它会导致不同城市之间原本存在差别的传播特性被逐渐抹平，使得关键信息丢失。

2.2.2 Graphormer 的结构偏置与机制改良

为打破局部聚合的限制，Graphormer 将 Transformer 的强大全局注意力机制引入图学习领域^[22]。它通过精巧的结构偏置设计，使模型能在全连接的虚拟图上，敏锐地感知到真实物理网络的底层拓扑。针对流感传播任务的特殊性——城市间空间关联由动态人口流动而非静态地理距离主导——本研究对 Graphormer 的三大编码机制进行了改进。

（1）中心度编码：节点的入度与出度反映了其在人口流动网络中的枢纽地位。原版 Graphormer 采用简单的向量加法将度嵌入与节点特征融合^[22]：

$$h_i^{(0)} = x_i + z_{\text{deg}^-(v_i)} + z_{\text{deg}^+(v_i)} \quad (2-11)$$

但这种线性叠加在数学上容易造成特征空间的正负对消。本研究采用拼接

（Concatenation）操作保留特征独立性：

$$h_i^{(0)} = \left[x_i \parallel z_{deg^-(v_i)}^- \parallel z_{deg^+(v_i)}^+ \right] W_{proj} \quad (2-12)$$

其中, $x_i \in R^H$ 为节点 i 的输入特征, $z_{deg^-(v_i)}^-, z_{deg^+(v_i)}^+ \in R^H$ 分别为入度和出度对应的可学习嵌入, $\parallel$ 表示拼接操作, $W_{proj} \in R^{3H \times H}$ 为可学习投影矩阵。该设计使模型能够独立地利用节点的拓扑重要性。

（2）空间编码：传统图自注意力通常引入节点间的最短路径长度（Shortest Path Distance, SPD）作为空间偏置^[22]，但在现代航空与高铁网络中，病原体传播前锋早已与地理距离脱钩。为此，本研究采用基于随机游走的扩散距离 d_{diff} （详见 2.4.2 节）替代 SPD，并将其融入注意力分数计算：

$$C_{ij}^{attn} = \frac{(h_i W^Q)(h_j W^K)^T}{\sqrt{d_k}} - \alpha \cdot d_{diff}(i, j) + \varepsilon_{ij} \quad (2-13)$$

其中, $W^Q, W^K \in R^{H \times d_k}$ 为查询和键的投影矩阵, d_k 为注意力头维度, α 为可学习缩放标量, ε_{ij} 为边编码项。这个偏置机制能够引导模型更关注那些尽管在地理上相隔很远、但人口往来非常频繁的核心传播通道, 从而帮助注意力更好地聚焦在这些关键走廊上。

（3）边编码：动态邻接矩阵 $A(t)$ 本身即是最具信息量的边特征。本研究将其作为边特征, 通过线性映射得到边编码 $\varepsilon_{ij} = A_{ij}(t)w^E$, 使模型能实时感知“封城”等交通管制措施对网络拓扑的影响。

上述改良的详细实现（包括多头注意力与门控密集连接）将在第四章展开。

2.2.3 门控时序卷积网络

在时序特征提取模块, 本研究选用门控时序卷积网络（Gated Temporal Convolutional Network, Gated TCN）而非 LSTM。时序卷积网络（TCN）是一种基于卷积神经网络的时序建模方法, 其核心思想是利用一维卷积处理序列数据。与循环神经网络不同, TCN 通过因果卷积（causal convolution）保证输出仅依赖于当前及过去的信息, 不会泄露未来数据, 从而严格满足时序预测的因果性。同时, 通过引入扩张卷积（dilated convolution）, TCN 能在层数较少的情况下指数级扩大感受野, 有效捕捉周度、月度的疫情周期性波动, 而无需堆叠大量循环单元。

Gated TCN 在标准 TCN 基础上增加双分支门控结构：一个分支使用 $\tanh$ 激活函数提取主要特征，另一个分支使用 sigmoid 激活函数作为信息保留比例的控制，两者逐元素相乘后输出。这种设计能够自适应地过滤数据采集过程中可能出现的噪声（如迟报、漏报造成的异常波动），为下游的 Graphormer 模块提供更纯净的时空特征。

相比 LSTM，Gated TCN 具有以下优势：一是卷积操作支持并行计算，训练效率更高；二是通过调整扩张因子和层数，可灵活控制感受野，避免 LSTM 中长序列梯度消失的问题；三是门控机制提供了类似 LSTM 的信息过滤能力，但结构更简单，更适合处理疫情数据中常见的非平稳性和噪声。

2.3 Kolmogorov-Arnold 网络

在传统深度学习中，多层感知机因其万能逼近定理而成为非线性映射的事实标准^[18]。然而，其“黑盒”属性以及对固定激活函数的依赖，在处理由微分方程约束的物理参数反演问题时，往往显得力不从心。

2.3.1 Kolmogorov-Arnold 表示定理

Kolmogorov-Arnold 表示定理为打破 MLP 的垄断提供了一个全新的视角^{[47][48]}。该定理指出，任意一个多元连续函数均可精确地表示为有限个单变量连续函数的加法组合。具体而言，对于函数 $f: [0,1]^n \rightarrow R$ ，存在单变量函数 $\phi_{q,p}$ 和 Φ_q ，使得：

$$f(x_1, x_2, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right) \quad (2-14)$$

这一发现意味着，复杂的高维映射可以被优雅地分解为一系列简单的一维函数的学习问题。

2.3.2 B 样条参数化与局部支撑

基于这一定理，KAN 架构应运而生。它将可学习的激活函数从网络“节点”上彻底移除，并直接放置在网络的“边”上。每个激活函数 $\phi(x)$ 被参数化为一个 B 样条曲线。B 样条的核心优势在于其局部支撑性——调整某个控制点只会影响曲线的一个小段，这使得网络训练更加稳定，且容易进行微调。

$$\phi(x) = w_b \text{SiLU}(x) + w_s \sum_i c_i B_i(x) \quad (2-15)$$

式(2-15)是 KAN 层的典型公式^[8]。第一项 $w_b SiLU(x)$ 提供了一个稳定的、类似残差的基函数连接,确保训练的稳定性;第二项 $w_s \sum_i c_i B_i(x)$ 则是 B 样条插值部分,其中的系数 c_i 正是网络需要学习的参数,负责捕捉数据的精细非线性结构。

2.3.3 在微样本场景下的权衡

需要强调的是,强大的表达能力也伴随着过拟合的风险,尤其是在本研究采用的严格时序划分导致训练样本极度稀缺的情况下。因此,本文在应用 KAN 时,并未追求过大的网格规模,而是通过约束 B 样条的网格点数量,并辅以差分平滑正则化,来抑制其高频抖动。这种设计使得模型既能利用 KAN 的优势精准地解码物理参数,又避免了在小数据集上把这些噪声信号也一并记进去的问题。

2.4 时空数据处理方法

再好的模型架构,如果没有高质量的数据作为支撑,也难以真正发挥出它的潜力。原始的百度迁徙指数仅为无量纲的相对热度,无法直接输入到基于绝对人口基数的 SEIR 动力学方程中。因此,对原始数据进行科学的处理与转换,是模型成功的关键一步。

2.4.1 重力模型重构绝对流量

为将无量纲的迁徙指数 $Index_{ij}$ 映射为具有人口量级的绝对流量 F_{ij} ,本研究引入了经典的重力模型^[43]:

$$F_{ij} = G \cdot \frac{P_i^\alpha P_j^\beta}{d_{ij}^\gamma} \quad (2-16)$$

其中, F_{ij} 表示从城市 i 到城市 j 的人口流动量; P_i 、 P_j 分别为两城市的常住人口规模; d_{ij} 为两城市间的地理距离。模型中, P_i^α 和 P_j^β 分别刻画源头城市的人口辐射能力与目标城市的人口吸引力,幂次 α 、 β 用于调整人口规模对流动的非线性影响; d_{ij}^γ 表征地理距离对流动的摩擦阻力,幂次 γ 控制距离的衰减强度; G 为全局比例常数。该模型假设城际人口流动量与城市人口规模成正比、与地理距离成反比,通过拟合历史迁徙数据可估计 α 、 β 、 γ 、 G 四个参数。

2.4.2 扩散距离的计算

单纯依靠地理距离，很难解释那些由人口流动带来的跨区域传播现象。因此本文采用扩散距离来衡量城市之间的关联强度，这种方式能更贴合实际的人口往来情况。

给定一个由重力模型重构的行随机转移概率矩阵 P ，其稳态分布为 π 。那么，城市 i 和 j 之间的扩散距离定义为它们经过 t 步随机游走后，到达其他所有节点的概率分布的加权差异：

$$d_{\text{diff}}(i, j) = \sqrt{\sum_{k=1}^n \frac{(P_{ik}^{(t)} - P_{jk}^{(t)})^2}{\pi_k}} \quad (2-17)$$

其中， $P_{ik}^{(t)}$ 表示从节点 i 出发经过 t 步随机游走到达节点 k 的概率， π_k 为稳态分布中节点 k 的概率质量。扩散距离的核心思想是利用图拉普拉斯的谱特性，将原本复杂的交通网络结构映射到一个低维流形上，从而提炼出节点间的空间邻近关系。在此度量下，即使北京与深圳相隔千里，只要人员流动频繁，它们的扩散距离就会很小，从而被 Graphormer 在第一层注意力中识别为潜在的“高危近邻”。这为模型提前预警跨区域传播提供了强大的空间偏置。

2.5 本章小结

本章完成了对 KAN-Graphormer 混合模型背后三大理论支柱的系统性梳理。从宏观的传染病动力学视角，论证了从 SIR 向 SEIR 模型过渡的必要性，并建立了基于有效再生数 R_t 的物理约束框架。在空间建模层面，通过对 Graphormer 进行拼接式中心度编码和基于扩散距离的空间偏置改进，使其能更精准地捕捉人口流动驱动的跨区域传播。在微观非线性映射层面，KAN 的引入为物理参数的解译提供了更强的可解释性和拟合效率。最后，通过重力模型和扩散距离，将原始流动数据转化为模型可用的、具有物理意义的特征。这三者在数学机理上的深度耦合，共同构筑了本模型在面对数据分布偏移时依然能够实现稳健预测的基础。

3 多源数据融合与实验设计

传染病时空动力学模型的预测性能，很大程度上取决于输入数据的质量以及实验验证的严谨性。高质量的数据底座是模型成功的关键前提。本章从数据生成的实际过程出发，详细说明多源异构数据如何被整理成驱动 KAN-Graphormer 模型的高维特征。3.1 节介绍流行病学数据和社会经济数据的采集来源；3.2 节阐述时空序列的降尺度处理、人口流量的物理重构以及特征归一化方法，特别注意防止数据泄露；3.3 节和 3.4 节围绕时间序列预测的实际场景，设计两种实验划分策略和评估指标体系，为后续模型验证奠定基础。

3.1 多源数据采集与整理

研究跨区域流感传播，仅靠病例数据难以完整刻画其复杂规律。本研究以 2020 年 1 月 10 日至 3 月 15 日（共 66 天）为观测期，选取了全国 24 个中心城市，融合人口流动、气象环境、社会经济等多维度信息，构建了包含六个维度的多源异构数据库。

3.1.1 流感病例与病原学数据

流感病例数据来自中国公共卫生科学数据中心。原始记录为省级月度发病数和死亡数，样例见表 3-1。由于模型需要城市级日度病例作为预测目标，原始数据的时空分辨率不足，需要通过后续处理进行降尺度。此外，为了捕捉流感的病原学变化趋势，从中国国家流感中心采集了对应周期的《流感监测周报》中的南北方流感病毒阳性率数据，如表 3-2 所示，以此作为后续时空降尺度（Downscaling）的核心权重约束。

表 3-1 流感原始数据样例（省级月度）

地区	日期	发病数(人)	发病率(1/10 万)	死亡数(人)
北京市	2020 年 1 月	73912	343.2026	12
天津市	2020 年 1 月	4730	30.2849	0
河北省	2020 年 1 月	23464	30.9063	3

华中科技大学硕士学位论文

表 3-2 2020 年南北方流感周度阳性率趋势 (%)

周结束日期	南方阳性率	北方阳性率
2020-01-12	48.1	42.3
2020-01-19	44.5	36.5
2020-01-26	39.2	32.5
2020-02-02	33.2	24.2
2020-02-09	16.3	11.5
2020-02-16	6.5	5.9
2020-02-23	1.7	4.1
2020-03-01	1.0	3.5
2020-03-08	1.0	1.4
2020-03-15	0.7	1.7

3.1.2 跨区域人口流动数据

城市间的人口迁徙是流感跨区域传播的主要载体。本研究通过百度迁徙平台获取 24 个城市之间每日的迁入和迁出热度指数。城市列表包括 4 个直辖市和 20 个省会/副省级城市（见表 3-3）。在构建图网络时，选择“迁出视角”建立有向加权邻接矩阵，因为从源头城市到目标城市的迁出流量更能直接反映病原体的输入风险。

表 3-3 24 个中心城市列表

城市代码	城市名称	城市代码	城市名称	城市代码	城市名称
110000	北京市	440300	深圳市	210200	大连市
120000	天津市	610100	西安市	370200	青岛市
310000	上海市	510100	成都市	370100	济南市
500000	重庆市	420100	武汉市	330200	宁波市
440100	广州市	330100	杭州市	350200	厦门市
440300	深圳市	320100	南京市	230100	哈尔滨市
610100	西安市	320500	苏州市	220100	长春市
510100	成都市	320200	无锡市	130100	石家庄市
420100	武汉市	410100	郑州市		
330100	杭州市	430100	长沙市		
320100	南京市	210100	沈阳市		

爬虫获取的原始数据为 CSV 格式,每个城市每天一个文件,包含迁入城市排名、迁出城市排名、迁入省份排名、迁出省份排名四类信息。样例见表 3-4。

表 3-4 百度迁徙原始数据样例 (北京市 2020-01-10)

rank_type	rank	value	target_city_name	target_province_name
move_in_city	1	19.64	廊坊市	河北省
move_in_city	2	8.70	天津市	天津市
...	...	...	...	...
move_out_city	1	15.54	廊坊市	河北省
move_out_city	2	8.37	保定市	河北省
...	...	...	...	...

3.1.3 城市静态属性与气象数据

城市的社会经济属性和气象条件是影响流感传播的基础因素。常住人口基数、地区生产总值 (GDP) 及区域供暖标识 (南方=1, 北方=0) 均来自各省市《2019 年国民经济和社会发展统计公报》及相关年鉴。值得注意的是,常住人口的定义参照《人口普查和抽样调查规定》:指居住在本乡镇街道、户口在本乡镇街道或户口待定的人口,以及居住在本乡镇街道、离开户口所在乡镇街道半年以上的人口。GDP 数据采用当年初步核算值。区域标识 (南方=1, 北方=0) 根据传统地理划分及供暖政策确定,用于捕捉南北方流感传播的区域异质性。

长春市因年鉴数据缺失,本实验以年末户籍人口替代。虽然户籍人口来代表实际居住人口,在一些人口流动较大的城市会存在一定偏差,但这种偏差在短期内基本是恒定的,在模型迭代过程中可以被接触修正因子这一参数所抵消,不会对最终的预测结果产生明显影响。环境气象数据则依托美国国家海洋和大气管理局 (NOAA) 的全球地面天气站日度摘要数据集。针对无直接映射站点的宁波、无锡、苏州三市,采用“天气后报”平台的实测数据作为补充。经严密的重叠样本交叉验证 (Pearson 相关系数大于 0.96), 确证了该填补策略在统计学上的高置信度。

3.1.4 城内出行与干预指标

城市内部的社交活动强度直接影响病毒传播。因历史交通接口受限,缺乏直接的

交通流量数据，本研究利用百度搜索指数中的“地铁”与“公交”的搜索热度作为城内出行活跃度的代理变量。对少量缺失值进行线性插值平滑处理，得到每日的公交指数和地铁指数，用以反映非药物干预措施下城市内部接触率的变化。

3.1.5 数据汇总

为清晰起见，表 3-5 汇总了各类数据的来源、原始形式及预处理后的用途。

表 3-5 多源数据集信息汇总

数据类型	来源	原始形式	预处理后用途
流感病例	中国公共卫生科学数据中心	省级月度发病数	经插值得城市日度病例（目标变量）
人口流动	百度迁徙平台（爬虫）	城市对日度排名及指数	构建动态邻接矩阵、扩散距离
社会经济	各市统计局统计公报	城市级年度数据	节点静态特征（人口、GDP、区域）
环境气象	NOAA、天气后报	城市日度气象观测	节点特征（气温、PM2.5 等）
城内出行	百度指数（手动收集）	城市日度搜索指数	节点特征（地铁/公交指数）
流感周报	中国国家流感中心	南北方周度阳性率	病例插值趋势修正、区域分析

3.2 时空序列的降尺度与拓扑特征重构

原始数据经过采集后，其时空分辨率各异、量纲不统一且分布存在噪声，需要通过插值、归一化与特征构造等预处理手段消除异质性，最终转换为 Graphormer 与 SEIR 迭代模块可解析的高维张量形式。

3.2.1 病例数据的时空降尺度与保形插值

将省级月度汇总病例分解为城市日度病例，是一个典型的病态逆问题。简单的按人口比例划分会丢失疫情的暴发峰值与长尾衰减特征。为此，本研究设计了两步降尺度方法：先在空间维度上按各市常住人口占全省比例将月度病例分配至各城市，再在时间维度上利用南北方周度流感阳性率的趋势作为演化骨架进行插值，从而在保留疫情峰谷特征的同时，满足病例数的非负与单调性物理约束。常规的三次样条插值

(Cubic Spline) 在处理此类具有突变性质的流行病学曲线时, 极易在间隔较大的已知点之间, 容易出现不符合实际情况的负值或震荡现象^[42]。为规避此风险, 本研究采用保形分段三次埃尔米特插值多项式 (PCHIP) 技术。PCHIP 通过限制插值区间内的单调性, 保证插值曲线平滑且不会出现异常振荡。其插值公式为:

$$p(t) = h_{00}(s)y_k + h_{10}(s)hd_k + h_{01}(s)y_{k+1} + h_{11}(s)hd_{k+1} \quad (3-1)$$

其中, t 为目标时刻, x_k 和 x_{k+1} 为相邻周度观测点的时间, $h = x_{k+1} - x_k$ 为区间长度, $s = (t - x_k)/h$ 为局部归一化位置, y_k, y_{k+1} 为观测值, d_k, d_{k+1} 为节点处的导数 (由 PCHIP 算法基于相邻点计算得到), $h_{00}, h_{10}, h_{01}, h_{11}$ 为三次 Hermite 基函数。该技术在平滑延长周度数据至日度粒度的同时, 保证了新增病例不可为负且单调趋势不发生畸变。

3.2.2 人口流动的绝对流量重构与扩散距离

百度迁徙指数是无量纲的相对值, 不能直接用于基于人口绝对数的 SEIR 模型。本研究采用重力模型将迁徙指数转化为绝对人口流动量, 其具体原理和公式已在 2.4.1 节详述, 此处不再赘述。通过重力模型重构出具有物理意义的流量矩阵后, 按行归一化得到马尔可夫转移概率矩阵 P 。

为替代传统的地理距离, 引入扩散距离来刻画城市间基于人口流动的真实传播关联。扩散距离的定义及其计算方法已在 2.4.2 节给出, 这里直接应用其计算结果。扩散距离较小的两个城市即使地理距离遥远, 只要人员流动频繁, 也会被视为空间邻近, 从而被图注意力机制重点关注。

3.2.3 特征组装与防泄露归一化

经过上述处理, 每个城市节点获得 16 维特征, 如表 3-6 所示。特征可分为病例相关、流动相关、静态属性、时序增强四类。表 3-6 中给出了每个特征的取值范围, 这些范围并非随意设定, 而是基于数据分布和代码中的截断逻辑确定的。例如, 病例增长率定义为 $(I_t/I_{t-1}) - 1$, 为避免分母为零和极端值, 在代码中截断至 $[-0.8, 2.0]$; 当前/平均比值截断至 $[0, 3.0]$ 以抑制异常脉冲。周度因子取值 $[0.8, 0.9]$ 是为了弱化周期波动对主要趋势的干扰。静态特征如城市等级和供暖标识本身是离散值, 不进行归

一化。

表 3-6 24 城市节点特征维度说明

维度	名称	计算方式	范围	类别
0	儿童病例	总病例 $\times$ 儿童年龄比例（三次样条插值得日度比例）	[0,2]	病例相关
1	成人病例	总病例 $\times$ 成人年龄比例	[0,2]	病例相关
2	老人病例	总病例 $\times$ 老人年龄比例	[0,2]	病例相关
3	公交指数	百度公交搜索指数，经插值后除以 100 归一化	[0,1]	流动相关
4	地铁指数	百度地铁搜索指数，同上	[0,1]	流动相关
5	气温	(日均气温 + 20) / 40，归一化至[0,1]	[0,1]	环境气象
6	人口密度	常住人口 / 行政区面积，取对数后归一化	[0,1]	静态属性
7	城市等级	一线=1，新一线=2，其他=3	{1,2,3}	静态属性
8	供暖标识	北方城市=1，南方城市=0	{0,1}	静态属性
9	封城强度	根据政策起止时间计算，0 表示无封城	[0,1]	干预相关
10	病例增长率	(当天病例/前 1 天病例) -1，截断至[-0.8,2.0]	[-0.8,2.0]	时序增强
11	7 日移动平均	病例的 7 日滑动平均，归一化	[0,1]	时序增强
12	当前/平均比值	当天病例 / 7 日移动平均，截断至[0,3]	[0,3]	时序增强
13	7 日移动标准差	病例的 7 日滑动标准差，归一化	[0,0.5]	时序增强
14	周度因子	$0.8 + 0.1 \times (\text{星期几}/6)$ ，反映周内波动	[0.8,0.9]	时序增强
15	疫情阶段	0（上升期）、0.5（平稳期）、1（下降期）	{0,0.5,1}	时序增强

防泄露归一化：在时序预测任务中，若使用全时间段的最大最小值进行归一化，会导致未来信息泄露到训练集。本研究实例化了严格的分城市对数极差归一化算子（City-Level Log-MinMax Scaler）。为从根源上切断未来信息对训练过程的污染，归一化操作被强制限定在训练集所覆盖的时间切片内进行拟合，提取历史区间的局部最大值与最小值作为固定标尺，并以此对验证集与测试集进行变换。对于城市等级、供暖标识等在时间轴上无波动的静态特征，其局部极差为零，则改用跨城市的全局极值池提取缩放因子。这一策略确保了训练与测试阶段在时间维度上的严格隔离，从根本上避免了数据穿越风险。

3.3 实验评估设计

为全面评估 KAN-Graphormer 模型在实际预测中的表现，设计了两种实验划分方案。

(1) 分布偏移的严格时序划分 (Chronological Split)

将 66 天的数据按时间顺序划分为训练集（前 60%，31 个样本）、验证集（20%，10 个样本）和测试集（20%，11 个样本）。这种划分模拟了真实预测场景：模型只能利用历史数据预测未来，而未来疫情可能因政策干预发生分布偏移（训练期主要为上升期和高峰期，测试期主要为下降期）。该方案用于检验模型在分布外泛化能力。这种由宏观政策干预引发的疫情数据内在规律剧变，使得基于历史经验建立的模型难以有效预测未来走势，对其泛化能力构成了严峻考验^[49]。

(2) 表征上限的随机划分对照 (Random Split)

将全部样本随机打乱，按 70%、15%、15% 的比例划分训练、验证和测试集。这种理想化的同分布场景用于评估模型的理论拟合上限，作为对照。

3.4 评估指标与实验环境

3.4.1 预测精度指标

针对多输出回归预测任务的特性，本研究选用以下三种标量评估指标，以从不同惩罚权重维度综合量度模型在测试集上的预测偏离度：

(1) 决定系数 (R^2 Score)：用于度量模型对靶变量空间方差的解释比例，是衡量系统拟合优度的核心标尺：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3-2)$$

(2) 均方根误差 (RMSE)：对预测序列中偶尔出现的大幅偏离（即离群误差）具有较高的惩罚敏感度：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3-3)$$

(3) 平均绝对误差 (MAE)：赋予所有样本误差同等的线性权重，反映了预测边界的整体稳健性：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3-4)$$

其中, y_i 为真实值, $\hat{y}_i$ 为预测值, $\bar{y}$ 为真实值均值, n 为样本总数。

3.4.2 参数合理性检验

除病例预测精度外, 评价 PINN 混合模型优劣的另一核心在于其推演出的流行病学参数是否符合物理规律。本研究确立了以下参数有效性区间: 时变传播率 β_t 的收敛域应约束在 $[0.10, 0.60]$ 以内; 而在严厉非药物干预背景下, 测试期的时变有效再生数 R_t 期望应呈现向 1.0 附近回落的态势。参数预测值落入合理先验区间 (如 $R_t \in [0.5, 2.0]$) 的样本比例作为模型物理自洽性的参考。

3.4.3 实验环境与随机种子

所有实验的代码构建与调试均依托于 Python 3.10 及 PyTorch 2.1 深度学习框架。硬件搭载 AMD Ryzen 7 7840H with Radeon 780M Graphics 处理器、16GB 内存及集成显卡, 所有计算任务均在 CPU 上完成。为确保消融实验间微小性能差异的统计显著性, 固定全局随机种子为 5780, 并采用三种不同种子进行补充实验以进行统计显著性检验。

3.5 本章小结

本章详细说明了用于 KAN-Graphormer 模型的多源数据采集、处理与实验设计。通过 PCHIP 插值将省级月度病例降尺度为城市日度序列; 利用重力模型将相对迁徙指数重构为绝对人口流量; 计算扩散距离替代地理距离以更准确刻画空间关联。特征工程中采用防泄露归一化, 确保训练和测试的时序独立性。实验设计了时序划分和随机划分两种方案, 并明确了评估指标和参数合理性标准。这些工作为后续模型验证提供了可靠的数据基础和实验框架。

4 基于 KAN-Graphormer 的混合预测模型

在传染病时空动力学建模中,纯数据驱动的深度学习往往存在“黑箱”问题,且在数据分布发生变化时泛化能力下降;而传统的动力学模型虽然具有明确的物理意义,但参数固定、难以表达复杂非线性关系。为克服这些局限,本章提出一种融合物理机制的 KAN-Graphormer 混合预测模型。4.1 节介绍模型的整体架构和数据流向;4.2 节详细阐述时空特征的提取与编码方法,包括时序卷积网络和改进的图注意力机制;4.3 节说明 KAN 模块的设计原理及其在动力学参数解码中的应用;4.4 节讨论多任务损失函数的构建和基于课程学习的训练策略;4.5 节给出消融实验的配置方案,为后续模型验证奠定基础。

4.1 模型总体框架

KAN-Graphormer 并非各算法组件的简单堆叠,而是按照“时序特征提取—空间依赖建模—非线性映射—物理约束解码”的逻辑串联而成。如图 4-1 所示,模型输入包括两部分:一是过去 7 天 ($T_{in} = 7$) 的 24 个城市节点特征矩阵 $X \in R^{N \times F \times T_{in}}$,其中 $N = 24$ 为城市数, $F = 16$ 为特征维度(详见第 3 章);二是反映城际人口流动的动态邻接矩阵序列 $A \in R^{N \times N \times T_{in}}$ 。模型的目标是预测未来 3 天 ($T_{out} = 3$) 各城市的新增病例数,并同时反演出具有流行病学意义的时变参数:传播率 β_t 、恢复率 γ_t 和接触修正因子 $contact_t$ 。

整个信息处理流程分为四个阶段:

- 时序特征提取 (Temporal Extraction): 利用门控时序卷积网络 (Gated TCN) 对每个城市的历史特征序列进行因果卷积,提取纯净的时间演化模式,得到压缩后的节点表征 $H_T \in R^{N \times H}$ 。
- 空间依赖建模 (Spatial Modeling): 将 H_T 输入改进的 Graphormer 模块,通过融入扩散距离偏置和中心度编码,捕捉由人口流动驱动的跨区域传播关联,输出空间融合表征 $H_S \in R^{N \times H}$ 。
- 非线性映射 (KAN Transformation): 用 KAN 模块替代传统 Transformer 中的

前馈网络，通过边上的 B 样条激活函数对 H_S 进行高维非线性变换，得到深层特征 $H_K \in R^{N \times H}$ 。

- 物理约束解码（Physics-informed Decoding）：多任务输出头将 H_K 映射为病例预测值与动力学参数 ($\beta_t, \gamma_t, \text{contact}_t$)。将参数代入离散化的 SEIR 反应-扩散方程，计算方程残差作为物理约束项加入总损失。




图 4-1 KAN-Graphormer 混合预测模型总体架构与信息流转图

4.2 时序特征提取与编码

4.2.1 时序特征提取：门控因果卷积

在时间序列建模中，循环神经网络（如 LSTM）虽然常用，但难以并行计算且容易发生梯度消失。更重要的是，其双向结构可能无意中泄露未来信息。为此，模型采用门控时序卷积网络（Gated TCN）[42]来提取时序特征，它通过堆叠的扩张因果卷积在保证因果性的同时获得较大的感受野。

如图 4-2 所示，该模块完全舍弃了递归结构，转而采用堆叠的扩张因果卷积（Dilated Causal Convolution）。为便于理解，先明确扩张因果卷积的离散形式：给定长度为 T 的输入序列 $x \in R^{T \times C_{in}}$ 和长度为 K 的卷积核 $f \in R^{K \times C_{in} \times C_{out}}$ ，扩张因子为 d 的因果卷积在时间步 t 的输出为：

$$y_t = \sum_{s=0}^{K-1} f_s \cdot x_{t-d \cdot s} \quad (4-1)$$

其中，当 $t - d \cdot s < 0$ 时， $x_{t-d \cdot s} = 0$ 。该操作确保了输出 y_t 仅依赖于当前及过去的输入，不会看到未来数据，且通过扩张因子 d 指数级扩大感受野。

在本模型中，将每个城市独立处理，将输入重塑为 $X' \in R^{(B \cdot N) \times T_{in} \times F}$ （ B 为批次大小），Gated TCN 的单层算子定义为：

$$H_t^{(l)} = \tanh(W_1 \star_d H^{(l-1)} + b_1) \odot \sigma(W_2 \star_d H^{(l-1)} + b_2) \quad (4-2)$$

式中， $\star_d$ 表示扩张因子为 d 的因果卷积运算，其具体实现即上述离散求和形式； $W_1, W_2 \in R^{K \times F \times H}$ 分别为滤波器与门控器的可学习卷积核； $b_1, b_2 \in R^H$ 为偏置； $\odot$ 代表 Hadamard 逐元素乘积。 $\tanh$ 分支负责特征的线性与非线性提取，而 σ (Sigmoid) 分支则充当了一个“软注意力阀门”——它能够自适应地过滤掉由数据迟报、漏报而引发的噪声。

通过堆叠两层扩张因子分别为 $d = 1$ 和 $d = 2$ 的卷积块，网络在不急剧膨胀参数量的前提下，实现了对长达 $1 + 2 = 3$ 个时间步感受野的全覆盖（实际通过叠加，感受野可覆盖更多历史步）。取序列最后一个时间步的输出，并恢复空间维度，即得到时序表征 $H_T \in R^{B \times N \times H}$ 。




图 4-2 Gated TCN 内部结构示意图

4.2.2 空间依赖建模：改进的 Graphormer

多区域流感传播的空间关联由人口流动网络决定，而非简单的地理邻近。为捕捉这种复杂空间依赖，模型引入 Graphormer 并针对传染病预测任务进行了两方面改进：中心度编码的拼接操作和空间编码的扩散距离偏置。




图 4-3 Graphormer 层的内部结构图

(1) 拼接式中心度编码。在流行病学干预中，节点的度中心性（如交通枢纽的进出港客流）直接影响其作为传播源的风险。原始 Graphormer 将节点度数的嵌入与

特征向量相加，这种线性叠加在数学上极易造成特征空间的正负对消，进而引发严重的信息坍缩。如图 4-3 所示，本文采用拼接方式：

$$h_i^{(0)} = [x_i \parallel z_{deg^-}(v_i^-) \parallel z_{deg^+}(v_i^+)]W_{proj} \quad (4-3)$$

式中， $x_i \in R^H$ 为节点 i 的时序特征； z_{deg^-} 与 z_{deg^+} 分别对应入度和出度的可学习嵌入（根据每日实际排名映射）。通过拼接操作 $\parallel$ 与线性降维矩阵 W_{proj} ，模型就保留了城市网络枢纽的异质性信息。

（2）扩散距离空间编码。传统的图自注意力机制通常引入节点间的最短路径长度（Shortest Path Distance, SPD）作为空间偏置^[22]，但在高铁和航空网络发达的今天，病原体传播更多依赖人口流动而非地理距离。因此，本文采用第 3 章（详见 3.2.2 节）中基于随机游走计算的扩散距离（Diffusion Distance, d_{diff} ）代替最短路径长度，将其作为偏置项加入注意力分数：

$$C_{ij}^{attn} = \frac{(h_i W^Q)(h_j W^K)^T}{\sqrt{d_k}} - \alpha \cdot d_{diff}(i, j) + \varepsilon_{ij} \quad (4-4)$$

式中， $W^Q, W^K \in R^{H \times d_k}$ 为查询和键的投影矩阵； d_k 为注意力头维度； α 为可学习的缩放因子； $\varepsilon_{ij} = A_{ij} W^E$ 为边编码，将实时人口流动强度 A_{ij} 映射为注意力增益。这一设计使模型重点关注那些虽然地理距离远但人员往来密切的城市对。

在叠加两层多头自注意力（MHA）网络后，为防止多层注意力带来的过平滑问题，引入了门控密集连接层^[23]：

$$H_S^{(l)} = H_S^{(l)} \odot \sigma(H_S^{(l)}) + H_D^{(l)} \odot (1 - \sigma(H_S^{(l)})) \quad (4-5)$$

其中，累积记忆变量 $H_D^{(l)}$ 为前 $l-1$ 层输出的累积。这一自适应门控机制允许每一个城市节点在深层交互后，动态决定是保留聚合后的全局信息，还是退回至保留个异性的局部特征，保持节点异质性。

4.3 KAN 非线性映射与参数解码

4.3.1 KAN 模块：可学习的边缘激活函数

传统 Graphormer 在注意力层之后，通常配置一个由两层线性层与固定激活函数（如 ReLU）构成的前馈网络。这种 MLP 结构将静态激活函数固定于网络节点，在

处理诸如“人口流动越过阈值引发感染率指数级激增”这类存在突变效应的物理过程时，其参数效率较低且可解释性有限。为提升非线性拟合能力并增强模型透明度，本研究采用 Kolmogorov-Arnold 网络对图模型的非线性映射模块进行替换。基于 Kolmogorov-Arnold 表示定理，KAN 将可学习的单变量函数置于网络边之上，取代了传统的线性权重矩阵。在具体实现中，采用兼顾反向传播稳定性与局部表征能力的残差 KAN 层：

$$\phi(x) = w_b \cdot \text{SiLU}(x) + w_s \cdot \sum_{i=0}^{G+K-1} c_i B_i(x) \quad (4-6)$$

其中， x 为输入标量； $\text{SiLU}(x)$ 为基函数，确保梯度平稳； $B_i(x)$ 为 K 阶 B 样条基函数，定义在由 G 个网格点划分的区间上； c_i 为可学习的控制点系数； w_b 和 w_s 分别为基函数和样条分支的缩放因子。由于 B 样条具有局部支撑性，调整某个控制点只影响局部区域，使训练更稳定。

将 Graphormer 输出的空间表征 H_S 输入 KAN 模块，并加入残差连接：

$$H_K = \text{LayerNorm}(H_S + g \cdot \text{KAN}(H_S)) \quad (4-7)$$

其中 g 为残差缩放因子，初始化为 0，使网络从恒等映射开始训练，逐步引入非线性。这种由深层注意力空间向 KAN 样条空间的降维映射，不仅以指数级减少了参数冗余，更使得模型能够敏锐地捕获到流感动力学方程中细微的高阶偏导数变化。

4.3.2 动力学参数解码与生物学约束

深层特征 $H_K \in R^{N \times H}$ 最终需要被解码为具有切实物理意义的流行病学指标。模型配置了四个独立的线性投影算子，分别输出未来 T_{out} 天的增量病例 $\hat{Y} \in R^{N \times T_{\text{out}}}$ 以及构成偏微分方程的三大核心张量：传播率 β_t 、恢复率 γ_t 与接触修正因子 contact_t （每个形状为 $N \times T_{\text{out}}$ ）。

病例预测头：由于病例数为非负值，采用 Softplus 激活函数确保输出非负，并裁剪至合理范围：

$$\hat{y}_{i,t} = \text{Softplus}(W_y h_i + b_y), \quad t = 1, \dots, T_{\text{out}} \quad (4-8)$$

在传染病暴发初期或强干预末期，日度新增病例常呈现长尾与零膨胀分布。若采用常规高斯或均匀参数初始化，输出层可能产生不合理的大幅初始值，导致后续 ODE 积分迭代中出现梯度爆炸。为解决此问题，本研究引入逆 Sigmoid 偏置初始化机制，

将输出层偏置设为接近真实数据全局均值的对数几率。同时，模型对解码通道施加生物学边界截断，确保推演参数不超出流感病毒的生理范围：

(1) 传播率 β 头：取值范围 $[0.1, 0.6]$ ，对应呼吸道病毒在不同管控强度下的基本传染力。

$$\beta_{i,t} = \text{Sigmoid}(W_\beta h_i + b_\beta) \times 0.5 + 0.1 \quad (4-9)$$

(2) 恢复率 γ 头：取值范围 $[0.14, 0.34]$ ，其倒数对应感染周期 3~7 天。

$$\gamma_{i,t} = \text{Sigmoid}(W_\gamma h_i + b_\gamma) \times 0.2 + 0.14 \quad (4-10)$$

(3) 接触修正因子 contact 头：取值范围 $[0.1, 1.6]$ ，反映社交隔离强度，0.1 对应完全封锁，1.6 对应报复性反弹。

$$\text{contact}_{i,t} = \text{Sigmoid}(W_c h_i + b_c) \times 1.5 + 0.1 \quad (4-11)$$

这种带限幅的输出层不仅提高了训练的稳定性，还赋予了参数明确的物理意义。

4.4 多任务损失与训练策略

4.4.1 多任务损失函数

模型的总损失函数定义在一个联合优化空间中，由数据拟合残差、物理方程约束和权重正则化三部分共同构成：

$$L = L_{\text{data}} + \lambda_1 L_{\text{physics}} + \lambda_2 L_{\text{reg}} \quad (4-12)$$

数据拟合损失：针对公共卫生监测数据中常见的漏报、补报等脉冲噪声，均方误差因其二次放大的特性容易使模型对离群点过度敏感。因此，本研究采用 Huber 损失替代均方误差：

$$\mathcal{L}_{\text{data}} = \frac{1}{NT_{\text{out}}} \sum_{i,t} \begin{cases} \frac{1}{2} (y_{i,t} - \hat{y}_{i,t})^2, & \text{if } |y_{i,t} - \hat{y}_{i,t}| \leq \delta \\ \delta \left(|y_{i,t} - \hat{y}_{i,t}| - \frac{1}{2} \delta \right), & \text{otherwise} \end{cases} \quad (4-13)$$

其中 δ 为阈值（取 1.0），该损失在误差较小时表现为 L2 范数以保障收敛稳定性，在误差超过阈值后则退化为 L1 范数以抑制异常值的影响，更适合处理疫情数据的非高斯噪声分布。

物理约束损失：利用模型反演得到的参数序列计算 SEIR 反应-扩散-漂移方程的残差 L2 范数，作为物理约束项加入损失函数：

$$\mathcal{L}_{\text{physics}} = \left\| \frac{\Delta I}{\Delta t} - D \nabla^2 I - \beta \frac{SI}{N} + \gamma I - v \cdot \nabla I \right\|_2^2 \quad (4-14)$$

这里 $\frac{\Delta I}{\Delta t}$ 为病例增量， D 为扩散系数， $\nabla^2 I$ 为空间拉普拉斯（用图拉普拉斯近似）， $v \cdot \nabla I$ 为漂移项（用人口流动加权）。残差越小，说明模型反演的参数越符合物理规律同时，以软约束（Soft Constraint）的形式将不同疫情阶段的先验基本再生数 R_0^{target} 引入损失网络中，防止底层物理参数收敛到无意义的局部极小值。

正则化损失：为控制模型复杂度并防止过拟合，引入正则化损失，包含 L1 和 L2 正则项：

$$L_{\text{reg}} = \lambda_{L1} \|\theta\|_1 + \lambda_{L2} \|\theta\|_2^2 \quad (4-15)$$

其中 θ 表示网络中所有可学习参数， λ_{L1} 和 λ_{L2} 为正则化系数。

4.4.2 基于课程学习的动态权重调整

在混合 PINN 模型的训练实践中，一个难题在于：若在初始化阶段便施加等权重的物理惩罚（即 λ_1 过大），网络会因无法同时拟合数据和满足方程，从而引发“正则化溢出（Regularization Spillover）”^[50]。为此，本研究设计了基于三阶段动态的课程学习（Curriculum Learning）策略^[45]：

（1）探索期（Epoch 0~10）：将 λ_1 极度压缩至 0.001。物理约束极弱，模型主要学习数据的统计规律。

（2）介入期（Epoch 11~30）：将 λ_1 线性增加至 0.03。网络在逼近数据标签的同时，物理约束逐渐增强，引导参数向合理范围靠拢。

（3）锁定期（Epoch 31~150）：维持 $\lambda_1 = 0.03$ 的高物理惩罚。同时依靠 KAN 内部的 L1/L2 正则化剔除冗余高频样条曲线，模型收敛到兼顾拟合精度和物理自治的解。

4.5 消融实验设置

为评估各模块的有效性，设计 7 种对比模型进行消融实验，如表 4-1 所示（在对比基线中参照了经典的 GCN^[51]与 GAT^[52]架构逻辑）。Full_KAN_Graphormer 是本文提出的完整模型（物理-数据双驱动）；NoPhysics_KAN_Graphormer 移除物理约束，

用于检验物理损失的作用；M_Graphormer_Baseline 将 KAN 换回 MLP，用于对比非线性映射方式的差异；KAN_Only 只保留时序特征和 KAN，无图结构；GAT_Baseline、LSTM_Baseline、MLP_Baseline 为传统基准模型。通过对比这些模型在时序划分和随机划分下的表现，可以定量分析各组件对预测精度和泛化能力的贡献。

表 4-1 核心消融模型控制变量与参数规模配置矩阵

模型代号	空间拓扑结构 (GNN)	核心激活与变换域	物理机制约束 (PDE)	网络参数量 (百万级)
Full_KAN_Graphormer (本文提出)	改进 Graphormer	KAN (B 样条边缘激活)	存在	约 2.36 M
NoPhysics_KAN_Graphormer	改进 Graphormer	KAN (B 样条边缘激活)	移除	约 2.31 M
M_Graphormer_Baseline	改进 Graphormer	MLP (节点固定激活)	存在	约 0.29 M
KAN_Only	移除 (纯时序)	KAN (B 样条边缘激活)	存在	约 0.19 M
GAT_Baseline	标准 GAT 弱图编码	MLP (节点固定激活)	移除	约 0.02 M
LSTM_Baseline	移除 (纯时序)	循环递归门控	移除	约 0.02 M
MLP_Baseline	移除 (纯时序)	全连接网络	移除	约 0.06 M

4.6 本章小结

本章详细阐述了 KAN-Graphormer 混合预测模型的架构设计。模型首先通过门控时序卷积提取历史病例的时序特征，再利用融入扩散距离偏置的 Graphormer 捕捉人口流动驱动的空间关联，然后以 KAN 模块进行高维非线性映射，最后解码出病例预测值和动力学参数，并通过物理约束损失确保参数合理性。在训练中采用 Huber 损失抵抗异常值、课程学习动态平衡数据拟合与物理约束。消融实验的设置将为后续章节的实证分析提供基准。该模型旨在兼顾预测精度与可解释性，为多区域流感传播预测提供新思路。

5 实验结果与分析

任何脱离实际数据生成过程的模型创新，其价值都需要经过严谨的实证检验。本章在严格时序预测的框架下，对 KAN-Graphormer 混合模型进行全面评估。5.1 节介绍实验设计；5.2 节分析模型训练收敛特性；5.3 节对比各模型在时序划分下的预测性能，并引入随机划分对照实验以揭示分布偏移对泛化能力的影响；5.4 节剖析反演出的动力学参数及其区域异质性；5.5 节通过注意力机制和 KAN 激活函数揭示模型的可解释性；5.6 节对残差进行诊断并验证模型稳定性。

5.1 实验设计：时序划分与对照基准

在流行病学时空建模中，时间序列数据具有显著的时域自相关性与不可逆的因果方向。若采用常规随机打乱划分，模型在训练时可能接触到与测试集时间邻近甚至未来的数据特征，造成未来信息泄露，从而高估模型的真实预测性能。为了让数据划分方式更贴近实际预测场景，也就是利用过去的的数据来推测接下来疫情的发展趋势，本文采用的是严格按照时间先后顺序来划分训练集、验证集和测试集，确保每一部分在时间上都不重叠。

在总共 52 个有效样本中，将前 31 个（对应疫情爆发和高位震荡期）作为训练集，用于学习传播规律；随后 10 个作为验证集，用于早停判断；最后 11 个作为测试集，完全隔离。值得注意的是，测试期正值全国范围内严格非药物干预措施生效阶段，病例数呈现明显下降趋势。这种由外部干预引起的数据分布变化，对模型的泛化能力构成了严峻考验^[49]。

为探究模型在理想同分布条件下的理论性能上限，另设随机划分对照实验（70% 训练、15% 验证、15% 测试）。所有实验固定核心随机种子（5780），同时采用三个不同种子（368、1037、5780）重复运行，以检验性能对初始化的敏感程度及统计稳健性，确保结论不受随机波动干扰。评估指标包括决定系数(R^2)、均方根误差(RMSE)、平均绝对误差(MAE)，同时关注反演参数的合理性（如有效再生数 R_t 落入 $[0.5, 2.0]$ 的比例）。

5.2 模型训练过程分析

把物理方程的残差作为正则项引入后，这种混合网络在优化高维非凸损失空间时，可能遇到数据拟合和物理约束两部分的梯度在大小或方向上不一致的问题。为解构 KAN-Graphormer 在此复杂优化环境下的收敛行为，实验提取了完整的训练曲线。

观察所有模型的训练过程图，发现所有模型均完成有效收敛且均无明显过拟合现象。如图 5-1 和图 5-2 所示，其中 Full_KAN_Graphormer 收敛速度最快、训练过程最平稳，无过拟合迹象，收敛速度、训练稳定性均优于采用阶梯式衰减学习率、需较多个 epoch 才完成收敛的 M_Graphormer_Baseline 基线模型，印证了融合物理约束与 KAN 激活的架构具备更高效的训练收敛特性。KAN-Graphormer 模型在初始 20 个 Epoch 内并未盲目追求数据损失的断崖式下跌，而是在物理约束项的牵引下平稳优化。进入中期后，验证损失平稳下降，模型在数据保真度与物理一致性之间达到良好平衡。即便加载了 KAN 样条计算与 PDE 张量推演，单轮 Epoch 运算耗时仍在可接受范围，证明了架构的实用性。




图 5-1 Full_KAN_Graphormer 训练损失与学习率曲线




图 5-2 M_Graphormer_Baseline 训练损失与学习率曲线

5.3 时序划分下的模型性能对比

为量化不同算法组件的贡献,本研究构建了涵盖纯数据基线(LSTM、MLP、GAT)、替换激活引擎的混合变体(M_Graphormer_Baseline、KAN_Only)以及剥离物理方程约束的消融网络(NoPhysics_KAN_Graphormer)在内的多层次对照矩阵,旨在系统评估时序建模、图结构与物理约束各自对预测性能的影响。所有模型均在固定随机种子(Seed=5780)下统一训练,测试集上的各项性能指标汇总于表 5-1。

从表 5-1 及图 5-3 可以观察到:首先,纯时序的 LSTM 模型表现最差($R^2 = 0.8993$, RMSE=2.4441)。这种偏差的可能成因在于, LSTM 的长期记忆机制过度依赖训练集中的增长趋势,当测试期进入外部干预引发的下降阶段时,模型因缺乏空间信息的校正与物理方程的约束,难以有效应对分布偏移,从而产生较大的预测误差。这一结果说明,单纯依赖时序记忆的方法在面对政策干预导致的数据分布漂移时,其泛化能力存在明显局限。

华中科技大学硕士学位论文

表 5-1 时序划分下各模型测试集预测性能与参数信息（种子 5780）

模型	架构机制分类	R^2	RMS E	MAE	β 均值± 标准差	R_t 均值± 标准差	Valid R_t 比例 (%)
Full_KAN_Graphormer	物理-数据双驱动	0.943	1.836	1.296	0.4867±0.0806	1.011±0.244	93.06
NoPhysics_KAN_Graphormer	纯数据驱动（图网络）	0.932	2.009	1.401	—	—	—
M_Graphormer_Baseline	物理-数据双驱动（MLP）	0.941	1.867	1.333	0.5520±0.0725	1.001±0.214	94.10
MLP_Baseline	纯数据驱动（基线）	0.944	1.830	1.301	—	—	—
LSTM_Baseline	纯数据驱动（时序）	0.900	2.444	1.693	—	—	—
GAT_Baseline	纯数据驱动（图网络）	0.925	2.113	1.467	—	—	—
KAN_Only	物理-数据双驱动（无图）	0.947	1.782	1.271	0.5602±0.0741	1.040±0.223	92.01




图 5-3 各基线模型测试集预测性能综合对比

其次，完全移除空间结构的 KAN_Only 模型取得了最高的拟合精度（ $R^2 =$

0.9465)。从统计学习角度看,在训练样本仅 31 个时间步的极小样本条件下,复杂的空间注意力机制可能带来一定的过拟合风险。KAN_Only 利用 B 样条的局部支撑特性,以较少的参数有效拟合了数据中的非线性模式。然而,这种纯时序模型无法提供跨区域传播的溯源能力,即其高精度牺牲了空间可解释性。

本文提出的 Full_KAN_Graphormer 模型取得了 $R^2 = 0.9432$ 的精度,略低于 KAN_Only,但显著优于无物理约束的变体 NoPhysics_KAN_Graphormer ($R^2 = 0.9320$)。加入 SEIR 反应-扩散方程作为物理约束,虽然略微降低了数值拟合精度,但换来了模型对传播机制的描述能力,即能够输出合理的动力学参数。从表 5-1 可以看出,Full 模型输出的有效再生数 R_t 均值为 1.011,落在流感干预后合理区间[0.5,2.0]内,且 93.06%的样本满足此范围。相比之下,M_Graphormer_Baseline 虽然也能输出参数,但其恢复率 γ 偏高 (0.3027),导致 R_t 均值略低 (1.001)。从这个角度看,以微小精度损失换取物理可解释性,在多区域传染病预测中具有重要价值。

表 5-2 多随机种子下各模型 R^2 的均值与标准差

模型代号	R^2 均值	R^2 标准差
MLP_Baseline	0.9268	0.0151
LSTM_Baseline	0.8995	0.0086
GAT_Baseline	0.9238	0.0113
M_Graphormer_Baseline	0.9359	0.0260
KAN_Only	0.9329	0.0152
NoPhysics_KAN_Graphormer	0.9277	0.0041
Full_KAN_Graphormer	0.9208	0.0261

此外,表 5-2 汇总了各模型在三次独立运行中决定系数 R^2 的均值与标准差。结果显示,Full_KAN_Graphormer 的 R^2 均值为 0.9208,标准差 0.0261,与 M_Graphormer_Baseline 的 0.9359 ± 0.0260 处于相近的波动水平,两者稳定性相当;而 M_Graphormer_Baseline 在纯预测精度上略占优势,但无法提供流行病学参数。KAN_Only 的 R^2 均值为 0.9329,标准差仅 0.0152,表现最为稳定且精度较高,却因缺乏空间建模能力而无法揭示跨区域传播机制。NoPhysics_KAN_Graphormer 的标准差最小 (0.0041),但其 R^2 均值 (0.9277) 略低于 Full 模型,且同样不具备物理参数输出能力。配对 t 检验显示,Full_KAN_Graphormer 与 NoPhysics_KAN_Graphormer 的 R^2 无显著差异 ($p=0.305$),证明物理约束模块在几乎不牺牲精度的前提下带来了完整的流行病学参数解释。Full_KAN_Graphormer 在牺牲微量预测精度的条件下,成功反

演了具有流行病学意义的物理参数，且其稳定性与同类模型相当，验证了该架构在实际应用中的可靠性。

进而分析城市尺度的预测误差，图 5-4 展示了 Full 模型在城市级的 R^2 热力图，Full 模型在北上广深等一线核心城市的 R^2 维持在 0.8490 的高位，在其他节点城市达到 0.9483。模型在面对高流动性城市时未出现“误差坍塌”，验证了 PDE 约束为高维映射流形提供了抗干扰的能力。




图 5-4 Full_KAN_Graphormer 城市级预测性能热力图

为了探究模型在理想同分布条件下的性能上限，额外进行了随机划分实验（70%训练、15%验证、15%测试）。在随机划分（IID 假设）的对照实验中，各模型的预测性能呈现出与主线时序划分截然不同的分布特征。LSTM_Baseline 取得了最高的真实空间 R^2 （0.6541），显著优于其他模型；相比之下，Full_KAN_Graphormer 的 R^2 仅为 0.4542，略低于其无物理约束的变体 NoPhysics_KAN_Graphormer（0.4898），而 GAT_Baseline 和 M_Graphormer_Baseline 的表现分别为 0.4117 和 0.4756，均未超越 LSTM。这一结果揭示两个关键事实：其一，在时间因果被完全打乱的同分布条件下，LSTM 凭借门控机制对滑动窗口内局部依赖的捕捉能力，取得了优于其他模型的拟

合精度；而具备全局图注意力机制的模型（GAT、Graphormer）并未如预期通过空间交互获得优势，其性能反而低于 LSTM，这暗示随机划分虽消除了时间概念漂移，却可能引入空间维度的数据泄露风险——图网络可能会利用同一时间段内其他城市的数据来间接提升自己的预测表现，而 LSTM 因为没有考虑城市间的空间联系，反而没有受到这方面信息的干扰。其二，Full_KAN_Graphormer 的性能略低于其无物理约束版本，微分方程的强制连续性在此无序数据场景中并未带来益处，但也未造成剧烈衰减，从反面印证了物理约束在主线时序划分下对泛化能力的正向作用。

因此，随机划分下的高分可能掩盖模型对真实时间因果的依赖，尤其图网络存在通过空间信息提高效果的潜在风险；主线实验采用的严苛时序滑动窗口划分，才是检验模型在真实预警场景下泛化能力的可靠基准。

5.4 动力学参数反演与区域异质性分析

与传统模型仅输出病例预测不同，KAN-Graphormer 还能反演出驱动疫情传播的物理参数。对测试期（疫情下降阶段）的输出进行统计，Full_KAN_Graphormer 估计的平均接触修正因子为 0.5345。这意味着在居家办公、交通限制等措施下，城市居民的有效接触强度降低了近 50%。基于此，模型计算的有效再生数 R_t 均值为 1.0105（标准差 0.2435），且 93.06% 的城市 R_t 落在 $[0.5, 2.0]$ 的合理范围内。传染病学指出， R_t 接近 1.0 表示疫情进入平稳消耗期，这与当时相关部门报告的宏观趋势吻合。这也说明模型采用的 Huber 损失和课程学习策略^[45]引导了参数收敛到合理的区间。

图 5-5 与图 5-6 展示了 Full_KAN_Graphormer 反演的关键流行病学参数。在测试期内，基础传播率 β 时序走势平稳，均值稳定在 0.487 附近且置信区间较窄，模型估计具有较高置信度；其数值主要集中在 0.4~0.6 之间，符合呼吸道病毒传播率的先验范围，且差分检测未出现突变点，与干预措施稳定的宏观背景一致。城市间对比显示南方城市的传播率普遍高于北方，反映了区域异质性。有效再生数 R_t 均值约为 1.011，时序上围绕流行阈值 1.0 小幅波动，约一半的城市 R_t 低于 1，处于疫情抑制状态，另一半略高于 1，处于临界传播状态。上述参数分布均符合流行病学基本规律，验证了模型在动力学参数反演方面的可靠性。




图 5-5 Full_KAN_Graphormer 反演的动态传播率分布：(a)时序演化均值及置信区间；(b)全样本统计分布直方图；(c)城市尺度平均传播率空间横向对比；(d)逐日一阶差分及突变点侦测




图 5-6 Full_KAN_Graphormer 反演的有效再生数分布：(a)时序演化均值与临界阈值对照；(b)全局 R_t 分布密度；(c)城市 vs 时间微观热力图；(d)样本点流行病学安全等级分类饼图

将城市按是否实施高强度封城分组对比。图 5-7 显示，实施封城管控的城市，模型反演的接触修正因子为 0.353，对应的有效再生数 R_t 降至 0.593，跌破 1.0 的流行阈值；未封城的参照城市接触修正因子为 0.560， R_t 达 1.070，仍处于流行临界区间。两组城市的病毒基础传播率 β 无统计学显著差异（ $p=0.558$ ），这一参数差异特征印证了非药物干预主要通过大幅降低人群有效接触强度遏制疫情，而非改变病毒自身的生物学传播特性。




图 5-7 封城效应对比：传播率、接触因子与 R_t




图 5-8 南北方城市传播率与 R_t 对比

在区域异质性方面，如图 5-8，将 Full_KAN_Graphormer 反演的参数按南方和北方城市分组统计发现：南方 13 个城市的平均传播率 β 为 0.5605，平均有效再生数 R_t 为 1.1676；而北方 11 个城市的 β 均值仅为 0.3993， R_t 均值为 0.8248。南方城市的基础传播率与有效再生数均极显著高于北方城市（ $p<0.001$ ），且南方有效再生数突破 1.0 的流行阈值，验证了模型对流感传播南北区域差异的精准捕捉能力，也与当时的毒株分布一致——南方以传播力较强的 A(H3N2)为主，北方则以 B 型 Victoria 系为主^{[55][56]}。

另外计算反演参数与城市静态特征的皮尔逊相关性，如图 5-9，“供暖地区”标识与传播率 β 呈强负相关($r=-0.633, p<0.01$)，与 R_t 亦高度负相关($r=-0.532, p<0.01$)。暗示北方供暖导致干燥环境可能抑制病毒存活，为区域差异提供了环境解释。




图 5-9 动力学参数与城市静态特征的 Pearson 相关性矩阵

5.5 可解释性分析：注意力机制与 KAN 激活函数

通过分析测试集最后阶段的注意力权重，Full_KAN_Graphormer 模型识别出的前五条强关联传播路径为：深圳→厦门、深圳→宁波、重庆→宁波、深圳→青岛、宁波→杭州。如图 5-10 所示，Full_KAN_Graphormer 的注意力分布呈显著非均匀特征，高权重集中于长三角、珠三角核心城市构成的非地理邻近城市对，而非相邻区域，验证了模型对流感跨区域远距离传播核心路径的有效捕捉能力，这反映了长三角和珠三角之间频繁的人员流动可能成为病毒远距离传播的重要通道。在复杂网络理论中

[53][54], 这些强连接可视为网络中的关键节点。




图 5-10 扩散距离驱动下的 Graphormer 城市群注意力拓扑与传播通道关联

图 5-11 是 Full_KAN_Graphormer 模型通过注意力机制识别的 24 个城市流感跨区域传播关联网络, 清晰呈现了以上海、北京、广州、深圳为核心枢纽的传播层级结构, 节点颜色代表城市传播核心度, 灰色连线对应城市间疫情传播的关联强度。该网络验证了模型可突破地理距离限制, 捕捉人员流动驱动的流感远距离传播规律。




图 5-11 扩散距离驱动下的 Graphormer 城市流感跨区域传播关联网络




图 5-12(a) Full_KAN_Graphormer 传播率反演模块 beta_head.0 激活函数分解




图 5-12 (b) Full_KAN_Graphormer 病例预测模块 case_head.0 激活函数分解

KAN 架构将可学习的 B 样条置于网络的突触连边上, 使得能直接观察输入特

征如何映射到输出。加载最佳预训练权重后，提取模型核心功能模块的 B 样条激活曲线并进行分解，图 5-12 (a) 显示，负责传播率 β 的激活曲线呈非对称指数形态，可学习 B 样条项与基础 SiLU 激活项协同实现了输入特征与传播率的正向非线性映射，精准适配了病毒传播的动力学特性；图 5-12 (b) 显示，负责病例预测的激活曲线呈现先平缓饱和后负向衰减的非线性形态，可学习 B 样条项主导了输入特征正负区间的差异化响应，匹配了病例预测对干预特征、时序特征的非线性拟合需求。这种无需人工预设先验、仅靠梯度反向传播便能为不同任务目标自主匹配最优非线性映射模式的特性，充分彰显了 KAN 架构在模型可解释性与任务适配性上的核心优势。

5.6 残差诊断与模型稳健性

评估预测模型的可靠性，除量化误差大小外，还需检验残差是否满足随机性与无偏性假设。




图 5-13 Full_KAN_Graphormer 模型时序外推残差的分布与自相关诊断：(a)残差时序图；(b)残差与预测值散点图；(c)直方图与正态拟合；(d)自相关函数图

如图 5-13, 对 Full_KAN_Graphormer 测试集残差的诊断结果显示, 残差时序走势整体围绕 0 值波动, 无显著单调趋势, 残差与预测值的散点分布无明显异方差特征; 残差均值为-0.3132, 标准差 0.7932, 偏度-0.1358, 峰度 0.3388, 其分布与正态拟合曲线高度契合, 说明模型无明显系统性偏差。自相关检验显示残差仅低阶滞后存在弱的自相关性, 计算得到的 Durbin-Watson 统计量为 1.0811, 虽未达到 2.0 的理想值, 存在一定时序自相关, 但对于受强外部干预影响的宏观传染病动力学模型, 该结果仍在可接受范围内, 验证了模型拟合的稳健性。

5.7 本章小结

本章在严格时序划分下对 KAN-Graphormer 进行了多维度评估。实验结果显示, 该模型在应对干预导致的分布偏移时, 不仅保持了较高预测精度 ($R^2 = 0.9432$), 更重要的是成功反演出具有流行病学意义的参数: 有效再生数 R_t 均值为 1.011, 93% 样本落入合理区间。通过与消融模型对比, 揭示了以微小精度损失换取物理可解释性的设计价值。通过注意力机制可以发现那些不受地理距离限制、主要由人口往来驱动的关键传播路径, 而 KAN 网络中的激活函数也能够根据预测任务的不同, 自己调整成合适的形态来适应数据中的非线性特征。区域异质性分析证实模型捕捉到了南北方毒株差异。残差诊断和多种子实验验证了模型的稳健性。综上, KAN-Graphormer 在精度与可解释性之间取得了有效平衡, 为多区域传染病预测提供了可行方案。

6 总结与展望

6.1 核心结论与全景回溯

本研究聚焦于流感等呼吸道传染病在复杂空间网络中表现出的强时空耦合、非线性演化及参数动态变化等关键问题，构建了融合 Kolmogorov-Arnold 网络与改进 Graphormer 的混合预测模型。回顾整个研究过程，从多源数据处理到时序外推验证，主要结论可归纳为以下三个方面：

（1）在数据重构与特征提取层面，研究验证了传统地理距离在现代交通网络下的局限性。通过引入重力模型将相对迁徙指数转换为绝对人口流量，并基于随机游走理论计算扩散距离，模型成功揭示了隐藏在复杂交通流背后的真实传播路径。同时，针对省级月度病例数据降尺度为城市日度序列的难题，采用保形分段三次插值（PCHIP）方法，在保证新增病例是非负的且趋势是合理的前提下，构建了跨度 66 天、包含 16 维特征的高质量时空数据集。值得注意的是，尽管数据预处理中采用了一些代理变量（如户籍人口替代常住人口、公交搜索指数代表城内出行强度），但模型内生的接触修正因子对这些近似误差具有一定的吸收能力，未导致系统性预测偏差。

（2）在模型架构的非线性表征方面，实验结果证实了 KAN 架构在处理流行病学非线性突变时的优势。通过将可学习的 B 样条激活函数部署在 Graphormer 的边上，替代传统多层感知机中的固定激活函数，KAN-Graphormer 有效缓解了图网络的过平滑问题，并结合拼接式中心度编码和扩散距离偏置，准确识别了跨区域传播的关键路径。需要指出的是，KAN 模块的稠密样条网格确实增加了参数量，但相较于其带来的参数可解释性和反演能力，这一代价在复杂决策场景下是可接受的。

（3）在极端分布偏移下的泛化能力方面，通过严格的时序划分实验，模型展示了物理约束与深度学习结合的优势。测试期正值封城干预导致的疫情下降阶段，纯数据驱动的 LSTM 模型因过度依赖历史增长趋势而性能下降，而 Full_KAN_Graphormer 在 Huber 损失与课程学习策略的协同下，保持了 $R^2 = 0.9432$ 的预测精度。模型反演的有效再生数 R_t 均值约为 1.01，接触修正因子反映了干预强度，与实际情况吻合；残

差分析显示 Durbin-Watson 统计量为 1.0811, 接近平稳随机波动。

6.2 方法学维度的创新凝练

本研究的主要创新体现在以下两个方面:

(1) KAN 与 Graphormer 的融合架构。本文将基于 Kolmogorov-Arnold 表示定理的 KAN 模块引入 Graphormer 的高维特征映射空间, 替代传统混合模型中依赖固定激活函数拟合偏微分方程残差的 MLP 结构。KAN 将可学习的 B 样条激活函数置于网络边缘, 利用其局部支撑特性捕捉人口流动阈值效应等复杂非线性关系, 拓宽了模型在流行病学参数反演任务中的表征能力。此外, 该设计为可解释性分析提供了新途径——通过观察 B 样条曲线的形态变化, 可以直观分析不同输入特征对模型输出的非线性影响。

(2) 物理约束机制与实验验证范式。针对小样本下物理信息网络易出现的正则化溢出问题, 本研究将反应-扩散-漂移方程离散化为物理监控器嵌入损失函数, 并通过逆 Sigmoid 偏置初始化和生物学阈值限幅操作抑制零膨胀数据引发的梯度异常。结合课程学习策略动态调整物理约束权重, 使模型在数据拟合与物理一致性之间实现有效平衡。在实验验证层面, 通过对比时序划分与随机划分两种评估范式, 揭示随机划分下模型可能借助空间维度信息泄露获虚假高分。这一对照体系为时空预测模型的可靠性评估提供了更严谨的方法学基准。

6.3 研究局限的反思与未来展望

受制于客观观测条件与算力资源限制, 本系统仍存在诸多亟待完善的局限:

(1) 数据代理误差的潜在影响。受限于微观公共卫生数据获取难度, 本研究在特征工程中采取了多项代理策略——使用长春市户籍人口替代常住人口基数, 以百度地铁公交搜索指数代表城内出行强度, 面对 NOAA 气象缺测时采用‘天气后报’数据替代。虽然模型内生的接触修正因子对这些近似误差有一定吸收能力, 但在长周期积分中仍可能累积为系统性漂移。仅 66 天的观测窗口无法覆盖流感跨年度的季节性变化模式, 这意味着模型对周期性规律的刻画能力有待进一步验证。

(2) 模型复杂度与算力开销。不可否认的是, KAN 模块在赋予模型非线性拟合能力的同时, 其稠密的 B 样条网格也不可避免地引发了参数量与计算开销的膨胀——在本实验中, 全量模型的单轮前向传播耗时显著高于基础的 MLP 与 GAT。同时, 当前的 SEIR 底座尚未引入无症状感染者仓室以及不同疫苗接种背景下的免疫屏障差异, 可能导致对绝对感染人数的估计偏保守。

(3) 未来研究方向。后续工作可从以下三方面展开。一是在数据广度上, 还需接入包含多种优势毒株迭代、跨越多波次流行高峰的长序列数据, 以检验模型对跨年周期变化的适应能力。二是在算法轻量化层面, 可尝试将原生的 KAN 算子替换为 ReLU-KAN 或 EfficientKAN 等变体, 利用基函数简化或参数共享来降低计算量, 以满足疾控平台的实时推断需求。三是在可解释性深化上, 下一步应致力于开发针对 KAN 激活曲线的自动符号回归工具。这不仅能直观地观察网络锁定了哪些关键传播路径, 更期望从高维张量中直接发现未知的流行病学方程, 真正实现人工智能与公共卫生决策的深度融合。

致 谢

转眼间，毕业论文即将完成，回望求学历程，心中充满感激与珍惜。感谢我的父母，你们的陪伴与支持始终让我坚强前行，无论顺境还是低谷，你们的理解与包容都是我最坚实的后盾。衷心感谢林聪萍导师，在我的研究生生涯给了我很多的帮助，您对学术严谨与认真的态度时刻引导着我，在我的论文选题、文献阅读、思维启发、模型研究等过程中起着至关重要的作用。同时也感谢其他给予帮助的老师，你们耐心的教诲和指导不仅传授知识，更启迪思考，亦是良师亦是益友。感谢一路相伴的朋友们，是你们的鼓励和欢笑让紧张的学习生活充满温暖与力量。我时常感到幸运，在这一路上有你们的指引和陪伴，学生时代虽然平凡，却因奋斗而闪光；那些在图书馆埋头修题、在苦思后迎来顿悟的瞬间，都成为青春里最珍贵的记忆。我很喜欢的一句话，“其实你什么都不用怕，走着走着，就又到了下一个回头看的日子”。每次熬过难关，都能见到新的曙光。

求学之路至此将暂告一段落，人生旅程仍将继续。学生时代教会我的，不只是知识，更是一种向上奋斗的力量和坚持不懈的态度。回望过去，我感激那些并不轻松的日子，它们让我在压力中成长，也更懂得珍惜每一个来之不易的机会；展望未来，我将带着这份感恩和热忱迎接新的学习与工作。“长风破浪会有时，直挂云帆济沧海”，面对未来我满怀憧憬和勇气，继续保持热情与坚持。未来的道路上，我愿始终保持初心，自立自强，脚踏实地，也不忘把温暖和快乐传递给身边的人。告别校园并非终点，而是新的开始。相信只要保持奋斗与勇气，美好的未来终会到来。

参考文献

- [1] WORLD HEALTH ORGANIZATION. Influenza (Seasonal) [EB/OL]. [2025-09-10]. [https://www.who.int/news-room/fact-sheets/detail/influenza-\(seasonal\)](https://www.who.int/news-room/fact-sheets/detail/influenza-(seasonal))
- [2] 中国国家流感中心. 流感监测周报 [EB/OL]. (2020-01-17) [2025-08-15]. <https://ivdc.chinacdc.cn/cnic/>
- [3] J. S. Jia, X. Lu, Y. Yuan, G. Xu, J. Jia, N. A. Christakis. Population flow drives spatio-temporal distribution of COVID-19 in China [J]. *Nature*, 2020, 582(7812): 389-394
- [4] M. U. G. Kraemer, C.-H. Yang, B. Gutierrez, C.-H. Wu, B. Klein, D. M. Pigott, et al. The effect of human mobility and control measures on the COVID-19 epidemic in China [J]. *Science*, 2020, 368(6490): 493-497
- [5] Y. Zhang, A. Zhang, J. Wang. Exploring the roles of high-speed train, air and coach services in the spread of COVID-19 in China [J]. *Transport Policy*, 2020, 94: 34-42
- [6] J. D. Murray. *Mathematical biology II: spatial models and biomedical applications* [M]. 3rd ed. New York: Springer, 2003
- [7] M. He, S. Tang, Y. Xiao. Combining the dynamic model and deep neural networks to identify the intensity of interventions during COVID-19 pandemic [J]. *PLoS Computational Biology*, 2023, 19(10): e1011535
- [8] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljacic, et al. KAN: Kolmogorov–Arnold Networks, in: *The Thirteenth International Conference on Learning Representations*, 2025
- [9] C. Guo, L. Sun, S. Li, Z. Yuan, C. Wang. Physics-informed Kolmogorov–Arnold network with Chebyshev polynomials for fluid mechanics [J]. *Physics of Fluids*, 2025, 37(9)
- [10] B. C. Koenig, S. Kim, S. Deng. KAN-ODEs: Kolmogorov–Arnold network ordinary differential equations for learning dynamical systems and hidden physics [J]. *Computer Methods in Applied Mechanics and Engineering*, 2024, 424: 116911
- [11] D. Brockmann, D. Helbing. The hidden geometry of complex, network-driven contagion phenomena [J]. *Science*, 2013, 342(6164): 1337-1342
- [12] W. O. Kermack, A. G. McKendrick. A contribution to the mathematical theory of

- epidemics [J]. Proceedings of the Royal Society of London. Series A, 1927, 115(772): 700-721
- [13] L. Tang, Y. Zhou, L. Wang, S. Purkayastha, L. Zhang, J. He, et al. A review of multi-compartment infectious disease models [J]. International Statistical Review, 2020, 88(2): 462-513
- [14] S. Feng, Z. Jin. Moment closure of infectious diseases model on heterogeneous metapopulation network [J]. Advances in Difference Equations, 2018, 2018(1): 339
- [15] V. Colizza, A. Vespignani. Epidemic modeling in metapopulation systems with heterogeneous coupling pattern: Theory and simulations [J]. Journal of Theoretical Biology, 2008, 251(3): 450-467
- [16] D. T. Citron, C. A. Guerra, A. J. Dolgert, S. L. Wu, J. M. Henry, H. M. Sánchez C., et al. Comparing metapopulation dynamics of infectious diseases under different models of human movement [J]. Proceedings of the National Academy of Sciences, 2021, 118(18): e2007488118
- [17] J. T. Wu, K. Leung, G. M. Leung. Nowcasting and forecasting the potential domestic and international spread of the 2019-nCoV outbreak originating in Wuhan, China: a modelling study [J]. The Lancet, 2020, 395(10225): 689-697
- [18] C. M. Bishop. Pattern recognition and machine learning [M]. New York: Springer, 2006
- [19] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, P. S. Yu. A comprehensive survey on graph neural networks [J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(1): 4-24
- [20] V. La Gatta, V. Moscato, M. Postiglione, G. Sperlí. An epidemiological neural network exploiting dynamic graph structured data applied to the COVID-19 outbreak [J]. IEEE Transactions on Big Data, 2021, 7(1): 45-55
- [21] A. Kapoor, X. Ben, L. Liu, B. Perozzi, M. Barnes, M. Blais, et al. Examining COVID-19 forecasting using spatio-temporal graph neural networks [J]. arXiv preprint arXiv:2007.03113, 2020
- [22] C. Ying, T. Cai, S. Luo, S. Zheng, G. Ke, D. He, et al. Do Transformers really perform bad for graph representation? [C]. in: Advances in Neural Information Processing Systems, 2021, 34: 28877-28888

- [23] X. Wang, Z. Jin. Multi-region infectious disease prediction modeling based on spatio-temporal graph neural network and the dynamic model [J]. PLoS Computational Biology, 2025, 21(1): e1012738
- [24] E. Kharazmi, M. Cai, X. Zheng, Z. Zhang, G. Lin, G. E. Karniadakis. Identifiability and predictability of integer- and fractional-order epidemiological models using physics-informed neural networks [J]. Nature Computational Science, 2021, 1(11): 744-753
- [25] J. Gao, R. Sharma, C. Qian, L. M. Glass, J. Spaeder, J. Romberg, et al. STAN: spatio-temporal attention network for pandemic prediction using real-world evidence [J]. Journal of the American Medical Informatics Association, 2021, 28(4): 733-743
- [26] Q. Cao, R. Jiang, C. Yang, Z. Fan, X. Song, R. Shibasaki. MepoGNN: Metapopulation epidemic forecasting with graph neural networks [C]. in: Machine Learning and Knowledge Discovery in Databases, Cham: Springer, 2023: 453-468
- [27] J. Mao, Y. Han, B. Wang. MPSTAN: Metapopulation-based spatio-temporal attention network for epidemic forecasting [J]. Entropy, 2024, 26(4): 278
- [28] M. Raissi, P. Perdikaris, G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations [J]. Journal of Computational Physics, 2019, 378: 686-707
- [29] C. de Boor. A practical guide to splines [M]. New York: Springer-Verlag, 1978
- [30] 中国疾病预防控制中心公共卫生监测与信息服务中心. 流行性感冒病例数据集 [EB/OL]. [2025-09-28]. <https://www.phsciencedata.cn/Share/edtShareNew.jsp>
- [31] 百度网讯科技有限公司. 百度迁徙规模指数数据集 [EB/OL]. [2025-10-18]. <http://qianxi.baidu.com/>
- [32] 国家统计局. 中国统计年鉴 2020 [M]. 北京: 中国统计出版社, 2020
- [33] 北京市统计局. 北京市 2019 年国民经济和社会发展统计公报 [EB/OL]. (2020-03-02)
- [34] 上海市统计局. 2019 年上海市国民经济和社会发展统计公报 [EB/OL]. (2020-03-29)
- [35] 广东省统计局. 广东统计年鉴 2020 [M]. 北京: 中国统计出版社, 2020

- [36] 成都市统计局. 成都统计年鉴 2020 [M]. 北京: 中国统计出版社, 2020
- [37] 陕西省统计局. 陕西统计年鉴 2020 [M]. 北京: 中国统计出版社, 2020
- [38] 湖北省统计局. 武汉统计年鉴 2020 [M]. 北京: 中国统计出版社, 2020
- [39] NOAA National Centers for Environmental Information. Global Surface Summary of the Day [DB/OL]. [2025-08-01]. <https://www.ncei.noaa.gov/data/global-summary-of-the-day/>
- [40] 天气后报. 历史天气查询 [EB/OL]. [2025-08-05]. <http://www.tianqihoubao.com/>
- [41] 百度指数. 搜索指数查询平台 [EB/OL]. [2025-08-10]. <https://index.baidu.com/>
- [42] F. N. Fritsch, R. E. Carlson. Monotone piecewise cubic interpolation [J]. SIAM Journal on Numerical Analysis, 1980, 17(2): 238-246
- [43] D. Chen, Y. Xue, Y. Xiao. Determining travel fluxes in epidemic areas [J]. PLoS Computational Biology, 2021, 17(10): e1009473
- [44] Y. N. Dauphin, A. Fan, M. Auli, D. Grangier. Language modeling with gated convolutional networks [C]. in: International Conference on Machine Learning, 2017: 933-941
- [45] Y. Bengio, J. Louradour, R. Collobert, J. Weston. Curriculum learning [C]. in: Proceedings of the 26th Annual International Conference on Machine Learning, 2009: 41-48
- [46] O. Diekmann, J. A. P. Heesterbeek, M. G. Roberts. The construction of next-generation matrices for compartmental epidemic models [J]. Journal of the Royal Society Interface, 2010, 7(47): 873-885
- [47] A. N. Kolmogorov. On the representation of continuous functions of many variables by superposition of continuous functions of one variable and addition [C]. in: Doklady Akademii Nauk SSSR, 1957, 114: 953-956
- [48] V. I. Arnol'd. On functions of three variables [J]. Doklady Akademii Nauk SSSR, 1957, 114(4): 5-8
- [49] J. Liu, Z. Shen, Y. He, X. Zhang, R. Xu, H. Yu, et al. Towards out-of-distribution generalization: A survey [J]. arXiv preprint arXiv:2108.13624, 2021
- [50] S. Wang, Y. Teng, P. Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks [J]. SIAM Journal on Scientific

- Computing, 2021, 43(5): A3055-A3081
- [51] T. N. Kipf, M. Welling. Semi-supervised classification with graph convolutional networks [C]. in: International Conference on Learning Representations (ICLR), 2017
- [52] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio. Graph attention networks [C]. in: International Conference on Learning Representations (ICLR), 2018
- [53] M. Salathé, M. Kazandjieva, J. W. Lee, P. Levis, M. W. Feldman, J. H. Jones. A high-resolution human contact network for infectious disease transmission [J]. Proceedings of the National Academy of Sciences, 2010, 107(51): 22020-22025
- [54] R. Pastor-Satorras, C. Castellano, P. Van Mieghem, A. Vespignani. Epidemic processes in complex networks [J]. Reviews of Modern Physics, 2015, 87(3): 925-979
- [55] J. Zou, H. Yang, H. Cui, Y. Shu, P. Xu, C. Xu, et al. Geographic divisions and modeling of virological data on seasonal influenza in the Chinese mainland during the 2006-2009 monitoring years [J]. PLoS One, 2013, 8(3): e58434
- [56] J. Yang, Y. C. Lau, P. Wu, L. Feng, X. Wang, T. Chen, et al. Variation in influenza B virus epidemiology by lineage, China [J]. Emerging Infectious Diseases, 2018, 24(8): 1536-1540

附录 1 攻读硕士学位期间取得的研究成果

- [1] 邵玲琳, 诸雯, 尹瑞琪. 灾难-环境耦合机制的多维度统计建模: 以川滇地区地震、降水与 NDVI 为例. 全国大学生统计建模大赛湖北赛区二等奖, 2025.

附录 2 其它附录

代码与数据可用性说明:

本研究所使用的全部源代码、原始数据及预处理脚本均已开源,并托管在 GitHub 代码仓库中,以便于研究结果的复现与验证。

- 仓库名称: KAN-Graphormer
- 仓库地址: <https://github.com/zhuzhu-z/KAN-Graphormer>
- 仓库内容说明:
 - code/: 包含数据爬取、预处理、模型训练(时序/随机划分)及可解释性分析的全部 Python 脚本。
 - data/raw/: 存放研究所用的原始数据文件,包括城市静态特征、分省/分年龄组流感病例、气象与搜索指数等。
 - requirements.txt: 运行代码所需的 Python 依赖库及版本信息。
 - README.md: 详细的项目说明、文件结构、运行环境配置及操作步骤。